

# Stochastik

Michael van Huffel

**Version: March 3, 2022**

This summary has been written based on the Lecture of Stochastik (401-0603-00L) by Prof. Dr. Patrick Cheridito (Autumn 21) and the summary of Till Richter. There is no guarantee for completeness and/or correctness regarding the content of this summary. Use it at your own discretion

0 Contents	
<b>1 Grundlage Wahrscheinlichkeitsrechnung</b>	<b>2</b>
1.1 Laplace Modell . . . . .	2
1.1.1 Rechenregeln . . . . .	2
1.2 Unabh�angigkeit . . . . .	2
1.3 Kombinatorik . . . . .	2
1.4 Zufallsvariable . . . . .	2
1.5 Bedingte Wahrscheinlichkeit . . . . .	2
1.6 Rechenregeln . . . . .	2
<b>2 Diskrete Verteilung</b>	<b>3</b>
2.1 Wahrscheinlichkeitsfunktion $p$ . . . . .	3
2.2 Kumulative Verteilungsfunktion . . . . .	3
2.3 Erwartungswert und Varianz (diskret) . . . . .	3
2.3.1 Rechenregeln . . . . .	3
2.4 Bernoulli $X \sim \text{BER}(p)$ . . . . .	3
2.5 Binomialverteilung $X \sim \text{BIN}(n, p)$ . . . . .	3
2.6 Geometrische Verteilung $X \sim \text{GEO}(p)$ . . . . .	3
2.7 Poissonverteilung $X \sim \text{POI}(\lambda)$ . . . . .	4
2.8 �bersicht diskreter Verteilungsfunktionen . . . . .	4
<b>3 Stetige Verteilung</b>	<b>4</b>
3.1 Erwartungswert und Varianz (stetig) . . . . .	4
3.2 Quantile $q(\alpha)$ . . . . .	4
3.3 Uniforme Verteilung $X \sim \text{UNI}(a, b)$ . . . . .	4
3.3.1 Summe gleichverteilter UNI Zufallsvariablen . . . . .	5
3.4 Exponentialverteilung $X \sim \text{EXP}(\lambda)$ . . . . .	5
3.4.1 �berlebenswahrscheinlichkeit . . . . .	5
3.5 Normal- / Gaussverteilung $X \sim \mathcal{N}(\mu, \sigma^2)$ . . . . .	5
3.6 Transformationen $Y = g(X)$ . . . . .	5
3.7 Simulation von Verteilungen . . . . .	6
3.8 �bersicht stetiger Verteilungsfunktionen . . . . .	6
<b>4 Deskriptive Statistik</b>	<b>6</b>
4.1 Kennzahlen . . . . .	6
4.2 Histogramm und Boxplot . . . . .	6
<b>5 Mehrdimensionale Verteilungen</b>	<b>7</b>
5.1 Diskret . . . . .	7
5.2 Stetig . . . . .	7
5.3 Transformationen . . . . .	8
5.4 Kovarianz und Korrelation . . . . .	8
5.4.1 Rechenregeln: . . . . .	8
5.4.2 Korrelation - Unabh�angigkeit . . . . .	8
5.5 Zwei-dimensionale Normalverteilung . . . . .	9
5.6 Lineare Prognose . . . . .	9
<b>6 Grenzwerts�tze</b>	<b>9</b>
6.1 Independent and identically distributed . . . . .	9
6.2 Funktionen von Zufallsvariablen . . . . .	9
6.2.1 Rechenregeln . . . . .	9
6.3 GGZ und ZGWS . . . . .	9
<b>7 Parametersch�tzungen</b>	<b>10</b>
7.1 Wahl der Verteilungsfamilie (QQ-Plot) . . . . .	10
7.1.1 Exponential QQ-Plot . . . . .	10
7.1.2 Normalverteilt QQ-Plot . . . . .	10
7.2 Methode der Parametersch�tzung . . . . .	10
7.2.1 Momentenmethode . . . . .	10
7.2.2 Maximum-likelihood Methode (MLE) . . . . .	11
7.2.3 Allgemeine Sch�tzer f�ur Erwartungswert und Varianz . . . . .	11
<b>8 Statistische Tests und Vertrauensintervalle f�ur eine Stichprobe</b>	<b>11</b>
8.1 Das Testproblem . . . . .	11
8.2 Eigenschaften von statistischen Tests . . . . .	11
8.2.1 Macht eines Tests . . . . .	11
8.2.2 P-Wert . . . . .	12
8.2.3 Multiples Testen . . . . .	12
8.3 Vertrauens- /Konfidenzintervalle . . . . .	12
8.3.1 Andere Verteilungen Vertrauensintervalle . . . . .	12
8.3.2 Statistische Signifikanz und fachliche Relevanz . . . . .	13
8.4 Binominalverteilte Test . . . . .	13
8.5 Tests Stichprobe bei normalverteilten Daten . . . . .	13
8.5.1 Z-Test . . . . .	13
8.5.2 t-Test . . . . .	14
8.6 Tests Stichprobe bei nicht normalverteilten Daten . . . . .	14
8.6.1 Vorzeichen-Test . . . . .	14
8.6.2 Wilcoxon-Test . . . . .	15
<b>9 Vergleich zweier Stichproben</b>	<b>15</b>
9.1 Gepaarte und ungepaarte Stichproben . . . . .	15
9.2 Gepaarte Vergleiche . . . . .	15
9.3 Zwei-Stichproben Test (ungepaarte Vergleiche) . . . . .	15
9.3.1 Mit $\sigma$ bekannt . . . . .	15
9.3.2 Mit $\sigma$ unbekannt . . . . .	16
<b>10 Lineare Regression</b>	<b>16</b>
10.1 Einfache lineare Regression . . . . .	16
10.1.1 Modell . . . . .	16
10.1.2 Parametersch�tzungen . . . . .	16
10.1.3 Tests und Vertrauensintervalle . . . . .	17
10.1.4 Computer Output Regression . . . . .	17
10.1.5 Vertrauensintervalle f�ur den Erwartungswert und Prognoseintervalle . . . . .	17
10.1.6 Typ von Plots . . . . .	17
10.2 Multiple lineare Regression . . . . .	18
10.2.1 Modell . . . . .	18
10.2.2 Parametersch�tzung . . . . .	18
10.2.3 Test und Vertrauensintervalle . . . . .	18

## 1 Grundlage Wahrscheinlichkeitsrechnung

- $\Omega$ : Ereignisraum, Grundraum
- $\omega$ : Elementarereignis (sich gegenseitig ausschliessende Ergebnisse)
- $A, B, C$ : Ereignis, Teilmenge von  $\Omega$
- Schnittmenge:  $A \cap B$  heisst "A und B"  
Falls  $A \cap B = \emptyset$ : A, B *disjunkt*
- Vereinigung:  $A \cup B$  heisst "'A oder B'"
- Komplement:  $A^c = \bar{A}$  heisst "'nicht A'"
- Differenz:  $A \setminus B = A \cap B^c$  heisst "'A ohne B'"

### 1.1 Laplace Modell:

Uniforme Verteilung:


$$\mathbb{P}[\omega] = 1/\Omega \quad \text{für alle } \omega$$

Alle Elementarereignisse haben gleiche Wahrscheinlichkeit!

$$\mathbb{P}[A] = \frac{|A|}{|\Omega|} = \frac{\#\omega \in A}{\#\omega \in \Omega}$$

#### Theorem: De Morgan'sche Regeln

1.  $(A \cap B)^c = A^c \cup B^c$
2.  $(A \cup B)^c = A^c \cap B^c = 1 - A \cup B$



#### 1.1.1 Rechenregeln:

- $A \cup B = B \cup A$
- $\mathbb{P}[A^c] = 1 - \mathbb{P}[A]$
- $\mathbb{P}[A^c] + \mathbb{P}[A] = 1$
- $\mathbb{P}[A \cup B] = \mathbb{P}[A] + \mathbb{P}[B] - \mathbb{P}[A \cap B] = \mathbb{P}[A \cap B^c] + \mathbb{P}[B]$
- $\mathbb{P}[A \cap B] = \mathbb{P}[A|B] \cdot \mathbb{P}[B] = \mathbb{P}[B|A] \cdot \mathbb{P}[A]$
- $\mathbb{P}[A \cap B]^c = \mathbb{P}[A^c] + \mathbb{P}[B^c]$

#### Theorem: Kolmogorov'sche Axiome

1.  $0 \leq \mathbb{P}[A] \leq 1$
2.  $\mathbb{P}[\Omega] = 1 \quad \mathbb{P}[\emptyset] = 0$
3.  $\mathbb{P}(\bigcup_{i=1}^m A_i) = \mathbb{P}[A_1 \cup \dots \cup A_m] \leq \mathbb{P}[A_1] + \dots + \mathbb{P}[A_m]$   
(wenn ausschliessend)

### 1.2 Unabhaengigkeit:

Eintreten von  $A$  beeinflusst WK von  $B$  nicht. (Kein kausaler Zusammenhang.)

$$\mathbb{P}[A \cap B] = \mathbb{P}[A] \cdot \mathbb{P}[B]$$

disjunkt  $\Rightarrow$  abhängig (falls  $\mathbb{P}[A], \mathbb{P}[B] > 0$ . Es gilt  $\mathbb{P}[A \cap B] = 0 \neq \mathbb{P}[A]\mathbb{P}[B]$ )

### 1.3 Kombinatorik:

$n$ : # in Grundmenge /  $k$ : # in Elemente

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

	Variation mit Reihenfolge	Kombination ohne Reihenfolge
mit Zurücklegen	$n^k$	$\binom{n+k-1}{k}$
ohne Zurücklegen	$\frac{n!}{(n-k)!}$	$\binom{n}{k}$

#### Hypergeometrische Verteilung:

Total  $N$ , betrachte  $C$ , davon  $K$  richtig in  $B \subset N$ ,  $C - K$  richtig in  $N - B$

$$\frac{\binom{B}{K} \cdot \binom{N-B}{C-K}}{\binom{N}{C}}$$

### 1.4 Zufallsvariable:

Funktion von  $\Omega$  nach  $\mathbb{R} : \omega \rightarrow X(\omega)$

- $X$  **diskret**, falls  $\omega$  "abzählbar"
- $X$  **stetig**, falls  $\omega$  "in einem Intervall"

$W$  := Wertebereich der Zufallsvariable


### 1.5 Bedingte Wahrscheinlichkeit:

$$\mathbb{P}[A|B] = \mathbb{P}[A \text{ gegeben } B] = \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]}$$

$$\mathbb{P}[A|B] \cdot \mathbb{P}[B] = \mathbb{P}[A \cap B] = \mathbb{P}[B \cap A] = \mathbb{P}[B|A] \cdot \mathbb{P}[A]$$

Falls  $A$  und  $B$  unabhaengig:

$$\mathbb{P}[A|B] = \mathbb{P}[A|B^c] = \mathbb{P}[A]$$



**Note:** Das Ereignis  $A$  kann geschrieben werden als  $A = (A \cap B) \cup (A \cap B^c)$

### 1.6 Rechenregeln:

- $\mathbb{P}(B|B) = 1$
- $\mathbb{P}(A_1 \cup A_2|B) = \mathbb{P}(A_1|B) + \mathbb{P}(A_2|B) - \mathbb{P}(A_1 \cap A_2|B)$
- $\mathbb{P}(A^c|B) = 1 - \mathbb{P}(A|B)$
- $\mathbb{P}(G \cap (G \cup B)) = \mathbb{P}(G)$  and  $\mathbb{P}(B \cap (G \cup B)) = \mathbb{P}(B)$
- $\mathbb{P}(A|B) \neq \mathbb{P}(B|A)$ , siehe Satz von Bayes
- $\mathbb{P}(A|B^c) = 1 - \mathbb{P}(A^c|B^c)$
- $\max\{0, 1 - \mathbb{P}(A^c) - \mathbb{P}(B^c)\} \leq \mathbb{P}(A \cap B) \leq \min\{\mathbb{P}(A), \mathbb{P}(B)\}$

#### Theorem: Satz der totalen Wahrscheinlichkeit


$k$  disjunkte Ereign.  $B_1, \dots, B_k$ , wobei  $B_1 \cup \dots \cup B_k = \Omega$ :

$$\mathbb{P}(A) = \sum_{i=1}^k \mathbb{P}(A \cap B_i) = \sum_{i=1}^k \mathbb{P}[A|B_i] \cdot \mathbb{P}[B_i]$$

### Theorem: Satz von Bayes

Fuer  $B_j$  disjunkte Ereignisse es gilt:

$$\mathbb{P}[B_i|A] = \frac{\mathbb{P}[A|B_i] \cdot \mathbb{P}[B_i]}{\mathbb{P}[A|B_1] \cdot \mathbb{P}[B_1] + \dots + \mathbb{P}[A|B_k] \cdot \mathbb{P}[B_k]}$$



## 2 Diskrete Verteilung

### 2.1 Wahrscheinlichkeitsfunktion p:

$$p(x_i) = \mathbb{P}[X = x_i] = \mathbb{P}(\{\omega : X(\omega) = x_i\})$$

Eigenschaften:  $p(x_i) \geq 0$ ,  $\sum p(x_i) = 1$

### 2.2 Kumulative Verteilungsfunktion:


Es gilt:

- $F(b) = \mathbb{P}[X \leq b] = \mathbb{P}(X \in (-\infty, b]) = \sum_{x_i < x} p(x_i)$
- $\mathbb{P}[X \in (a, b]] = \mathbb{P}(a < X \leq b) = F(b) - F(a)$
- $\mathbb{P}(X > x) = 1 - \mathbb{P}(X \leq x) = 1 - F(x)$

Die kumulative Verteilungsfunktion  $F$  erfuehlt zudem immer:

- $F$  ist **monoton steigend**:  $F(x_1) \leq F(x_2) \forall x_2 > x_1$
- $F$  ist **rechtsstetig**:  $\lim_{h \rightarrow 0} F(x+h) = F(x)$
- $\lim_{x \rightarrow \infty} F(x) = 1$  und  $\lim_{x \rightarrow 0} F(x) = 0$

#### Example: Verteilung Wahrscheinlichkeit Wurfel



### 2.3 Erwartungswert und Varianz (diskret):

**Erwartungswert** (mittlere Lage):

$$\mu_x = \mathbb{E}(X) = \sum_{x_i \in W} x_i \cdot p(x_i), \quad \mathbb{E}(g(X)) = \sum_{x_k \in W} g(x_k) \cdot p(x_k)$$

**Varianz** (Streuung):

$$Var(X) = \sigma_x^2 = \mathbb{E}[(X - \mathbb{E}(X))^2] = \sum (x_i - \mu_i)^2 p(x_i)$$

$$Var(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X)$$

**Standardabweichung:**

$$\sigma_x = \sqrt{Var(X)}$$

### 2.3.1 Rechenregeln:

- $\mathbb{E}[a + bX] = a + b\mathbb{E}[X]$
- $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$
- $Var(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$
- $Var(a + bX) = b^2 Var(X)$
- $Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$

### 2.4 Bernoulli $X \sim BER(p)$ :


Experimente mit ja/nein Ergebnis,  $p(x = \{0, 1\})$

$$X = \begin{cases} 1 & \text{Wahrscheinlichkeit } p \\ 0 & \text{Wahrscheinlichkeit } 1 - p \end{cases}$$

**Note:**  $Var[X(1 - X)] = 0$

#### Example: Bauteilen

Wenn  $X \sim BER(p) \Rightarrow X^n \sim BER(p)$



### 2.5 Binomialverteilung $X \sim BIN(n, p)$ :

Wiederholung eines Bernoulliexperimentes


#Wiederholungen:  $n$ , WK Erfolg:  $p$ , #Erfolge:  $x$

**Note:** if  $n$  big, wegen ZGWS:  $BIN(n, p) \approx \mathcal{N}(np, np(1 - p))$

#### Example: Bauteilen

Aus 10 Bauteilen WK, dass 1 defekt hat:

$$\mathbb{P}(X \geq 1) = \mathbb{P}(X = 1) + \dots + \mathbb{P}(X = 10) = 1 - \mathbb{P}(X = 0)$$



### 2.6 Geometrische Verteilung $X \sim GEO(p)$ :

Anzahl Wiederholungen  $x$  bis Erfolg mit  $BER(p)$  (WK  $p$ ).


$$F(x) = \mathbb{P}(X \leq x) = \sum_{i=1}^x p(1-p)^{i-1} = 1 - (1-p)^x$$

#### Example: Mindeste Versuche

Mindeste # Versuche bis 50% Chance Erfolg?

$$F(n) \geq 0.5, \text{ solve for } n$$

**Note:**  $1 - F(n)$  ist die Chance kein Erfolg bis  $n$ .



## 2.7 Poissonverteilung $X \sim \text{POI}(\lambda)$ :

Verteilung # Ereignisse fuer seltene Ereignisse ( $p$  klein) bei viele ( $n$  gross) unabhängige Versuche.

**Note:**


- $n$  gross,  $p$  klein:  $\text{BIN}(n, p) \sim \text{POI}(\lambda = np)$
- if  $\lambda$  gross, wegen ZGWS:  $X \approx \mathcal{N}(\lambda, \lambda)$

Anzahl pro Zeiteinheit:  $x$ , Schnitt pro Zeiteinheit:  $\lambda$   
Bsp: Radioaktiver Zerfall, Callcenter

$$X \sim \text{POI}(\lambda_1) \quad Y \sim \text{POI}(\lambda_2) \quad (X + Y) \sim \text{POI}(\lambda_1 + \lambda_2)$$

**Note:**  $\mathbb{E}(X \cdot Y) = \lambda_1 \lambda_2$  wenn  $X, Y$  unabhängig sind.

**Note:** Wenn wir aber  $\frac{1}{2}(X + Y)$  betrachten, so liegt keine Poissonverteilung vor mit Parameter  $\frac{1}{2}(\lambda_1 + \lambda_2)$ . Der Grund ist ganz einfach: Nur schon der Wertebereich stimmt nicht für eine Poissonverteilung! Der Erwartungswert ist aber  $\frac{1}{2}(\lambda_1 + \lambda_2)$ .



## 2.8 Übersicht diskreter Verteilungsfunktionen:

Verteilung	$p(x)$	$W_X$	$\mathbb{E}[X]$	$\sigma^2$ $\text{Var}(X)$
$\text{BER}(p)$	$p^x(1-p)^{1-x}$	$\{0, 1\}$	$p$	$p(1-p)$
$\text{BIN}(n, p)$	$\binom{n}{x} p^x (1-p)^{n-x}$	$\{0, \dots, n\}$	$np$	$np(1-p)$
$\text{GEO}(p)$	$p(1-p)^{x-1}$	$\{1, 2, \dots\}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
$\text{POI}(\lambda)$	$\frac{\lambda^x}{x!} e^{-\lambda}$	$\{0, 1, \dots\}$	$\lambda$	$\lambda$

## 3 Stetige Verteilung

Da  $\mathbb{P}[X = x] \approx 0$  betrachtet man  $\mathbb{P}[x \leq X \leq x + h]$

**Note:** If  $X_1, X_2$  identisch verteilt, so ist  $\mathbb{P}(X_1 \leq X_2) = 0.5$ .


**Wahrscheinlichkeitsdichte  $f$ :**

$$f(b) = F'(b) = \lim_{h \rightarrow 0} \frac{\mathbb{P}[x \leq b \leq x + h]}{h}$$

Mit der **kumulativen Verteilungsfunktion  $F(x)$ :**

$$F(x) = \mathbb{P}[X \leq x] = \int_{-\infty}^x f(u) du$$

$$\mathbb{P}(a < X \leq b) = F(b) - F(a) = \int_a^b f(x) dx$$



**Note:**  $F_X^2(x) = \mathbb{P}[X^2 \leq x] = \mathbb{P}[X \leq \sqrt{x}] = \int_{-\infty}^{\sqrt{x}} f_X(x) dx$

## Eigenschaften:

- $f(x) \geq 0$   $F$  ist steigend.
- $\int_{-\infty}^{\infty} f(x) dx = 1$ ,  $F(-\infty) = 0$   $F(\infty) = 1$
- $f(x) > 1$  ist möglich!

### 3.1 Erwartungswert und Varianz (stetig):


- $\mathbb{E}[X] = \mu_x = \int_{-\infty}^{\infty} x \cdot f(x) dx$
- $\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx$
- $\text{Var}(X) = \sigma_x^2 = \int_{-\infty}^{\infty} (x - \mu_x)^2 \cdot f(x) dx$
- $\text{Var}(X) = \mathbb{E}((x - \mathbb{E}[X])^2) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$

### 3.2 Quantile $q(\alpha)$ :

$$\mathbb{P}[X \leq q(\alpha)] = \alpha \quad q(\alpha) = F^{-1}(\alpha)$$

**Note:**


- Median wenn  $\alpha = 1/2$
- Verteilung symmetrisch  $\Rightarrow q_{\frac{1}{2}} = E(X)$
- Median ist robuster gegen Ausreisser als Erwartungswert
- Fuer empirische Quantile siehe 4.1.**



### 3.3 Uniforme Verteilung $X \sim \text{UNI}(a, b)$ :

Stetige Version des Laplace-Modells, benutzt für Messfehler,  $W = [a, b]$

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{else} \end{cases} \quad F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & x \in [a, b] \\ 1, & x > b \end{cases}$$



## Eigenschaften:

- $\mathbb{E}[X] = \frac{(a+b)}{2}$
- $\text{Var}(X) = \sigma_X^2 = \frac{(b-a)^2}{12}$
- $\text{Median}(X) = \frac{a+b}{2}$
- Auf einen Kreis:  $f(x, y|r) = \begin{cases} \frac{1}{r^2} \pi, & x^2 + y^2 \leq r^2 \\ 0, & \text{else} \end{cases}$
- k-tes Moment
- $m_k = \frac{1}{k+1} \sum_{i=0}^k a^i b^{k-i} = \frac{1}{k+1} \sum_{i=0}^k (\mu - \sqrt{3}\sigma^2)^i (\mu + \sqrt{3}\sigma^2)^{k-i}$
- k-tes zentrales Moment
- $\mu_k = \begin{cases} \frac{(b-a)^k}{2^k(k+1)} & k \text{ gerade} \\ 0 & k \text{ ungerade} \end{cases} = \begin{cases} \frac{\sqrt{3}^k \sigma^k}{(k+1)} & k \text{ gerade} \\ 0 & k \text{ ungerade} \end{cases}$

### 3.3.1 Summe gleichverteilter UNI Zufallsvariablen:


Wenn Breite gleich  $\Rightarrow$  Dreiecksverteilt, sondern trapezförmige Verteilung. Geg: Intervall  $[a,b]$ , die andere auf dem Intervall  $[c,d]$ . Sei  $\alpha = \min\{d-c, b-a\}$  und  $\beta = \max\{d-c, b-a\}$ :

$$f: \mathbb{R} \rightarrow \mathbb{R}, x \mapsto \begin{cases} 0 & x \notin [a+c, b+d] \\ \frac{x}{\alpha\beta} - \frac{a+c}{\alpha\beta} & x \in [a+c, a+c+\alpha] \\ \frac{1}{\beta} & x \in [a+c+\alpha, a+c+\beta] \\ \frac{b+d}{\alpha\beta} - \frac{x}{\alpha\beta} & x \in [a+c+\beta, b+d] \end{cases}$$

### 3.4 Exponentialverteilung $X \sim \text{EXP}(\lambda)$ :

Einfachstes Modell für Wartezeiten auf Ausfälle,  $W = [0, \infty)$ .

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0 \quad F(x) = 1 - e^{-\lambda x}, \quad x \geq 0$$



#### Eigenschaften:

- $\mathbb{E}[x] = \sigma_X = \frac{1}{\lambda}$
- $\text{Var}(X) = \sigma^2 = \frac{1}{\lambda^2}$
- $q_\alpha = \frac{\ln \frac{1}{1-\alpha}}{\lambda}$
- k-tes Moment:  $\mathbb{E}(X^k) = \frac{k!}{\lambda^k}$
- Sind  $X_1 \sim \text{Exp}(\lambda_1), \dots, X_n \sim \text{Exp}(\lambda_n)$  stochastisch unabhängig, so ist  $\min(X_1, \dots, X_n) \sim \text{Exp}(\lambda_1 + \dots + \lambda_n)$
- Sind  $X_1 \sim \text{Exp}(\lambda_1), \dots, X_n \sim \text{Exp}(\lambda_n)$  stochastisch unabhängig, so ist  $X_1 + \dots + X_n$  eine Linearkombination von Exponentialverteilungen,  $\lambda_i$  alle gleich, so ist die Summe  $\sim \text{Erl}(n, \lambda)$  **Erlang-verteilt**: ( $\mathbb{E}(x) = \frac{n}{\lambda}$ ,  $\text{Var}(x) = \frac{n}{\lambda^2}$ )

$$f_{\sum_{i=1}^n X_i} = \frac{\lambda^n \cdot x^{n-1}}{(n-1)!} e^{-\lambda x} \quad F(x) = \begin{cases} 1 - e^{-\lambda x} \sum_{i=0}^{n-1} \frac{(\lambda x)^i}{i!} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

#### Example: Poissonprozesse und Ausfall von $n$ Sys.

1. Sei  $N(t)$  die Anzahl Ereignisse im Zeitintervall  $[0, t]$ ,  $t \in \mathcal{R}$ . Für einen sogenannten homogenen Poissonprozess gilt  $N(t) \sim \text{POI}(\lambda t)$ .  $T_1$  = Zeitpunkt des ersten Ereignisses. Es gilt:

$$\{T_1 > t\} = \{\text{Kein Ereignis in } [0, t]\} = \{N(t) = 0\}$$

$$\mathbb{P}(T_1 \leq t) = 1 - e^{-\lambda t}$$

Zeit bis ersten Ereignis:  $T_1 \sim \text{Exp}(\lambda) \Rightarrow$  wegen Unabhängigkeit gilt im allgemein: Zeiten zwischen zwei aufeinanderfolgenden Ereignissen exponential-verteilt sind.

2. Ausfall von  $n$  Komponenten  $\mathbb{P}(x) = 1 - e^{-n\lambda x}$

### 3.4.1 Überlebenswahrscheinlichkeit:

Es ergibt sich unmittelbar die auf einen Zeitpunkt  $x_0$  bezogene bedingte Überlebenswahrscheinlichkeit:

$$\mathbb{P}(X > x_0 + x | X > x_0) = \frac{e^{-\lambda(x_0+x)}}{e^{-\lambda x_0}} = e^{-\lambda x}$$

### 3.5 Normal- / Gaussverteilung $X \sim \mathcal{N}(\mu, \sigma^2)$ :

Modell für Verteilung von Messwerten,  $W = \mathbb{R}$ .

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2} \left(\frac{(x-\mu)}{\sigma}\right)^2\right)$$

$$\mathbb{E}[X] = \mu \quad \sigma_X = \sigma$$

Verteilfunktion  $F(x)$  nicht geschlossen darstellbar. Wenn  $X_1, X_2$  Unabhängig:


$$X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), \quad X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2), \quad X_1 \pm X_2 \sim \mathcal{N}(\mu_1 \pm \mu_2, \sigma_1^2 + \sigma_2^2)$$

Bei der  $\mathcal{N}(0, 1)$ -Verteilung gilt:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{x^2}{2}\right\} \quad \text{and} \quad \Phi(x) = \int_{-\infty}^x \varphi \tilde{x} d\tilde{x}$$

$$F(x) = \mathbb{P}(X \leq x) = \Phi\left(\frac{x-\mu}{\sigma}\right) = \Phi(u)$$


$$f(x) = \frac{1}{\sigma} \varphi\left(\frac{x-\mu}{\sigma}\right)$$



#### Eigenschaften:

- $\mathbb{P}(X \geq x) = 1 - \Phi(u)$
- $\Phi(u) = 1 - \Phi(-u)$
- $\mathbb{P}(a \leq X \leq b) = F(b) - F(a)$
- $\mathbb{P}(|X - \mu| \leq k \cdot \sigma) = 2\Phi(k) - 1$
- Normalapproximation:

$$\mathbb{P}\left[\underbrace{s}_{\sim \mathcal{N}(\mu, \sigma^2)} \leq k\right] = \mathbb{P}\left[\underbrace{\frac{s-\mu}{\sigma}}_{\sim \mathcal{N}(0,1)} \leq \frac{k-\mu}{\sigma}\right] = \Phi\left(\frac{k-\mu}{\sigma}\right)$$



**Note:** Ca. 66% der Fläche befindet sich im Intervall  $[\mu - \sigma, \mu + \sigma]$ , ca. 95% der Fläche im Intervall  $[\mu - 2\sigma, \mu + 2\sigma]$ .

### 3.6 Transformationen $Y = g(X)$ :

**Linear:**  $g(x) = a + b \cdot x, \quad \rightarrow \quad Y = a + b \cdot X$

$$\mathbb{E}[Y] = a + b \cdot \mathbb{E}[X] \quad \text{Var}(Y) = (|b|)^2 \cdot \text{Var}(X)$$

$$F_Y(y) = F_X\left(\frac{y-a}{b}\right), \quad \text{falls } b > 0$$

$$F_Y(y) = 1 - F_X\left(\frac{y-a}{b}\right), \quad \text{falls } b < 0$$

$$f_Y(y) = \frac{1}{|b|} f_X\left(\frac{y-a}{b}\right)$$

## Standardisierung:

$$g(x) = \frac{x - \mu}{\sigma}, \quad \mathbb{E}[Z] = 0, \quad \text{Var}(Z) = 1$$

**Allgemein** (monoton steigend):

$$\mathbb{E}[Y] = \mathbb{E}[g(x)] = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx \geq g(\mathbb{E}[X])$$

$$\text{Var}(Y) = \mathbb{E}[Y^2] - \mathbb{E}[Y]^2$$

$$f_Y(y) = F'_Y(y) = \left| \frac{1}{g'(g^{-1}(y))} \right| \cdot f_X(g^{-1}(y))$$

Quantile transformieren einfach mit:  $q_{\alpha, X} \Rightarrow q_{\alpha, Y} = g(q_{\alpha, X})$

### Example: Verteilungsfunktion von eine Transformation

Sei:  $f_Z(z)$  für  $z > 0$  definiert. Die Verteilungsfunktion von  $\ln(1 + Z)$  ist gleich (für  $t > 0$ , sonst  $F(t) = 0$ ):

$$F(t) = \mathbb{P}(\ln(1 + Z) \leq t) = \mathbb{P}(Z \leq e^t - 1) = \int_0^{e^t - 1} f_Z(z) dz$$

**Lognormalverteilt:**

$$Y \sim \text{LOG}(\mu, \sigma^2) \leftrightarrow \log(Y) \sim N(\mu, \sigma^2)$$

$$Y = e^x \text{ aus } X \sim N(\mu, \sigma^2)$$

Es gilt:

- $\mathbb{E}[Y] = \exp\left(\frac{\mu + \sigma^2}{2}\right)$
- $\mathbb{E}[\ln(X)] = \mu$
- $P[a < X < b] = P[\ln a < \ln X < \ln b] = \Psi\left(\frac{\ln b - \mu}{\sigma}\right) - \Psi\left(\frac{\ln a - \mu}{\sigma}\right)$

**Paretoverteilt:**

$$Y = e^x \text{ aus } X \sim \text{EXP}(\alpha)$$

Es gilt:

- $P[X \geq x] = x^{-\alpha}$
- $f_Y(x) = \alpha \cdot x^{-(\alpha+1)}$
- $F_Y(x) = 1 - x^{-\alpha}$

## 3.7 Simulation von Verteilungen:

Sei  $X \sim U(0, 1)$  und  $Y = F^{-1}(X)$  mit beliebigem  $F$ !  
 $Y$  hat gerade die Verteilungsfunktion  $F$ .

- $X \sim U(0, 1) \Rightarrow A = \{x_1, x_2, \dots, x_n\}$
- $F(Y) = F^{-1}(X) = F^{-1}(A)$

## 3.8 Übersicht stetiger Verteilungsfunktionen:

Verteilung	$p(x)$	$W_X$	$\mathbb{E}[X]$	$\text{Var}(X)$
$\text{UNI}(a, b)$	$\frac{1}{b-a}$	$[a, b]$	$(a+b)/2$	$(b-a)^2/12$
$\text{EXP}(\lambda)$	$\lambda e^{-\lambda x}$	$\mathbb{R}_+$	$1/\lambda$	$1/\lambda^2$
$\text{Gamma}(\alpha, \lambda)$	$\frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$	$\mathbb{R}_+$	$\alpha/\lambda$	$\alpha/\lambda^2$
$\mathcal{N}(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$	$\mathbb{R}$	$\mu$	$\sigma^2$

## 4 Deskriptive Statistik

### 4.1 Kennzahlen:

**Arithmetisches Mittel**, abhängig von Ausreissern:

$$\bar{x} = \frac{1}{n}(x_1 + \dots x_n)$$

**Empirische Varianz:**

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

**Empirische Kovarianz:**

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})$$

**Empirischer Korrelationskoeffizient:**

$$r = \frac{s_{xy}}{s_x \cdot s_y} \in [-1, 1], \quad r = +1 \Leftrightarrow y_i = a + bx_i, b > 0$$

$$r = -1 \Leftrightarrow y_i = a + bx_i, b < 0$$

$\text{sign}(r)$  gibt Richtung,  $|r|$  die Stärke der linearen Abhängigkeit.

**Empirische kumulative Verteilungsfunktion:**

$$F_n(x) = \frac{1}{n} \text{Anzahl}\{i | x_i \leq x\} \in [0, 1]$$

**Empirisches  $\alpha$ -Quantil**  $q_\alpha$ , ( $0 < \alpha < 1$ ):

Bei **geordneten Werten**  $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$  ist  $q_\alpha = x_{(k)}$ , wobei mit  $k$  die kleinste ganze Zahl, so dass  $x_{(k)} > \alpha n$ .

Die Werte werden also etwa im Verhältnis  $\alpha : (1 - \alpha)$  aufgeteilt.  
 Das Quantil ist *robust gegenüber Ausreissern*.

$$q_\alpha = \begin{cases} \frac{1}{2}(x_{(\alpha \cdot n)} + x_{(\alpha \cdot n + 1)}), & \text{if } n \text{ gerade} \\ x_{(\lceil \alpha \cdot n \rceil)}, & \text{else} \end{cases}$$

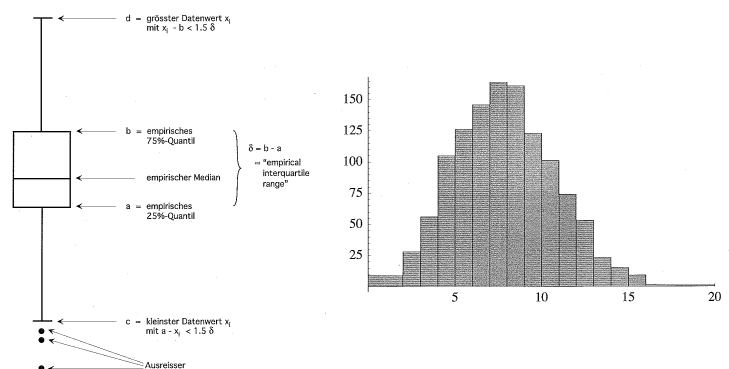
Median	$q_{0.5}$
unteres Quartil	$q_{0.25}$
oberes Quartil	$q_{0.75}$
Quartilsdifferenz	$QD = q_{0.75} - q_{0.25}$
	robuste Kennzahl für Streuung

### 4.2 Histogramm und Boxplot:

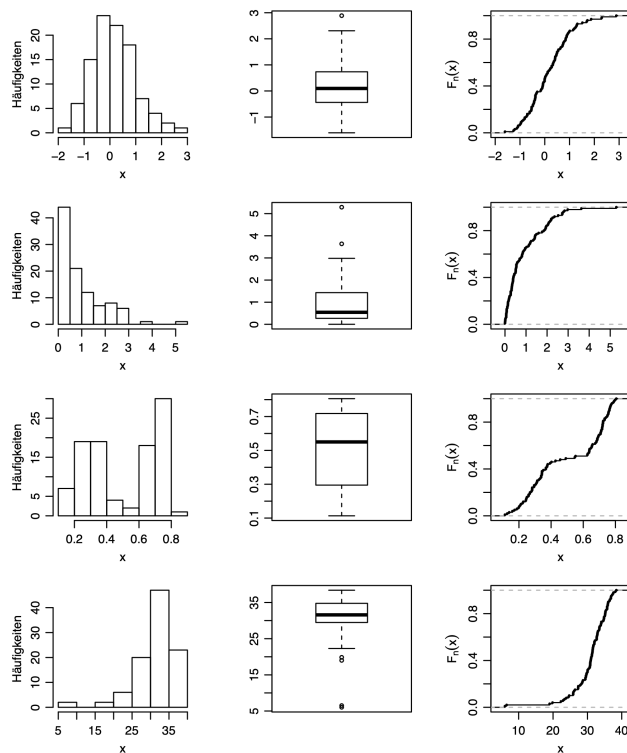
**Histogramm:** Einteilung der Werte in Klassen (Gesamtfläche Histogramm = 1)

- Intervalle  $(c_{k-1}, c_k]$
- Fläche der Balken  $\sim h_k$  mit  $h_k$ : Häufigkeit, Anzahl Werte im Intervall
- Höhe der Balken  $\sim \frac{h_k}{c_k - c_{k-1}}$

**Boxplot:** Rechteck begrenzt durch das 25%- und 75%-Quantil und dickem Strich für den Median, Linien von grösstem bis kleinstem "normalen" Wert (max. 1.5 mal die Quartilsdifferenz), Ausreisser: Sterne







## 5 Mehrdimensionale Verteilungen

### 5.1 Diskret:

#### Wahrscheinlichkeitsfunktion

$$\mathbb{P}(X = x, Y = y) \rightarrow \text{Tabelle}$$

$$\mathbb{P}(X \leq x, Y \leq y) = \sum_{\substack{x_i \in W_x | x_i \leq x \\ y_i \in W_y | y_i \leq y}} \mathbb{P}(X = x_i, Y = y_i)$$

#### Randverteilungen: WK'funktionen

$$\mathbb{P}(X = x) = \sum_{y \in W_Y} \mathbb{P}(X = x, Y = y)$$

$$\mathbb{P}(Y = y) = \sum_{x \in W_X} \mathbb{P}(X = x, Y = y)$$

#### Zweidimensionale Verteilungstabelle

$$F(x, y) = \sum_{x_i \leq x} \sum_{y_k \leq y} p(x_i, y_k)$$

#### Bedingte Verteilungen: WK'funktionen

$$\mathbb{P}(X = x | Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}$$

$$\mathbb{P}(Y = y | X = x) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(X = x)}$$

**Note:** Die Randverteilung von  $X$  (gleich fuer  $Y$ ) ist also:

$$\mathbb{P}(X = x) = \sum_{y \in W_Y} \mathbb{P}(X = x | Y = y) \mathbb{P}(Y = y)$$

#### Erwartungswert von $g(X, Y)$ , ( $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ )

$$\mathbb{E}[g(X, Y)] = \sum_{x \in W_x, y \in W_y} g(x, y) \mathbb{P}(X = x, Y = y)$$

#### Bedingter Erwartungswert

$$\mathbb{E}[X | Y = y] = \sum_{x \in W_x} x \cdot \mathbb{P}(X = x | Y = y)$$

$$\mathbb{E}[Y | X = x] = \sum_{y \in W_y} y \cdot \mathbb{P}(Y = y | X = x)$$

**Note:** Wenn  $X, Y$  unabhängig  $\Leftrightarrow$  (alle Aussage equivalent)

- $\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x) \mathbb{P}(Y = y), \forall x \in W_x, y \in W_y$
- $\mathbb{P}(X + Y \in [a, b]) = \sum_{n \in [a, b]} \sum_{k=0}^n \mathbb{P}(X = k) \cdot \mathbb{P}(Y = n - k)$
- $\mathbb{P}(X = x | Y = y) = \mathbb{P}(X = x), \forall x \in W_x, y \in W_y$
- $\mathbb{P}(Y = y | X = x) = \mathbb{P}(Y = y), \forall x \in W_x, y \in W_y$

### 5.2 Stetig:

$$\mathbb{P}[(X, Y) \in A] = \int \int_A f_{X,Y}(x, y) dx dy$$

$$F(x, y) = \mathbb{P}(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

#### Dichte (oder gemeinsame Verteilung):

$$f(x, y), \quad f: \mathbb{R}^2 \rightarrow \mathbb{R}$$

#### Randverteilungen: Dichten

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx$$

#### Bedingte Verteilungen: Dichten

$$f_Y(y | X = x) = \frac{f_{X,Y}(x, y)}{f_X(x)} \quad f_X(x | Y = y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

#### Erwartungswert von $g(X, Y)$ , ( $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ )

$$\mathbb{E}[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) \cdot f_{X,Y}(x, y) dx dy$$


#### Bedingter Erwartungswert

$$\mathbb{E}[X | Y = y] = \int_{-\infty}^{\infty} x f_X(x | Y = y) dx$$

$$\mathbb{E}[Y | X = x] = \int_{-\infty}^{\infty} y f_Y(y | X = x) dy$$

**Note:** Wenn  $X, Y$  unabhängig  $\Leftrightarrow$  (alle Aussage equivalent)

- $f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y) \quad F(x_1, x_2) = F(x_1) \cdot F(x_2)$
- $f_X(x | Y = y) = f_X(x), \forall x \in W_x, y \in W_y$
- $f_Y(y | X = x) = f_Y(y), \forall x \in W_x, y \in W_y$






### Example: Maschinen Lebensdauer

Seien  $X$  und  $Y$  unabhängig und  $Exp(\lambda_i)$  verteilt. So ist:

$$f_{X,Y}(x,y) = \lambda_1 e^{-\lambda_1 x} \lambda_2 e^{-\lambda_2 y}$$

$$\mathbb{P}(Y < X) = \int_0^\infty \int_0^x f_{X,Y}(x,y) dy dx$$



### Example: Wurfel und Mutze Experiment

Experiment: Zuerst Wurfel einmal geworfen (Resultat =  $Y$ ). Dann wird  $Y$ -mal Mutze geworfen.  $X$  bezeichne die Anzahl "Kopf" aus den  $Y$  Mutzenwürfen.

$$\mathbb{P}(X = k | Y = j) = \begin{cases} \text{BIN}(j, 0.5)(k), & k \in \{0, \dots, j\} \\ 0, & k > j \end{cases}$$

Note:

- $\mathbb{P}(Y = j) = \frac{1}{6}$
- $\mathbb{P}(X = k) = \sum_{i=k}^j \mathbb{P}(X = k | Y = i) \cdot \mathbb{P}(Y = i)$
- $\mathbb{E}(X) = \sum_{k=1}^6 k \mathbb{P}(X = k) = \sum_{k=1}^6 \sum_{j=1}^6 k \mathbb{P}(X = k | Y = j) \mathbb{P}(Y = j)$

### 5.3 Transformationen:

Seien  $X$  und  $Y$  **unabhängige** ZV mit Dichten  $f_X, f_Y$ .

**Summe:**  $f_{X+Y}(t) = f_X(t) * f_Y(t) = \int_{\mathbb{R}} f_X(u) \cdot f_Y(t-u) du$

$$\mathbb{P}(X + Y \leq z) = \int_0^z \int_0^t f_X(u) \cdot f_Y(t-u) du dt$$

**Produkt:**  $f_{X_1 \cdot X_2}(z) = \int_{X_1 \cdot X_2 = z} \frac{1}{|t|} f_{X_1}(t) \cdot f_{X_2}\left(\frac{z}{t}\right) dt$

**Quotient:**  $f_{X_1/X_2}(z) = \int_{X_1/X_2 = z} |t| f_{X_1}(z \cdot t) f_{X_2}(t) dt$

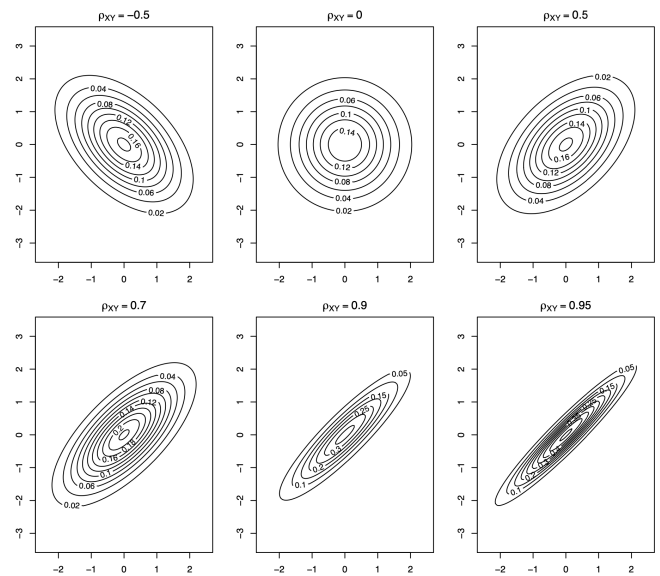

### 5.4 Kovarianz und Korrelation:

Kovarianz und Korrelation sind Kennzahlen, welche die Abhängigkeit von Zufallsvariablen beschreiben.

**Kovarianz:**  $Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$

Die Korrelation misst Stärke und Richtung der **linearen Abhängigkeit** zwischen  $X$  und  $Y$ .

$$\text{Corr}(X, Y) = \rho_{XY} = \frac{Cov(X, Y)}{\sigma_X \cdot \sigma_Y}$$



**Note:** Im Bild stehen Beispiele für empirische Korrelationen

### Example: Kovarianz aus Wahrscheinlichkeitstabelle

Gegeben sei die Tabelle der Wahrscheinlichkeit  $\mathbb{P}(X = k, Y = j)$  für  $k, j = 0, 1$ . Dann ist:

- $\mathbb{E}[X] = \mathbb{P}(X = 1) = \mathbb{P}(X = 1 | Y = 0) + \mathbb{P}(X = 1 | Y = 1)$
- $\mathbb{E}[Y] = \mathbb{P}(Y = 1) = \mathbb{P}(X = 0 | Y = 1) + \mathbb{P}(X = 1 | Y = 1)$
- $Cov(Y_1, Y_2) = \underbrace{\mathbb{E}[XY]}_{=\mathbb{P}(X=1|Y=1)} - \mathbb{E}[X]\mathbb{E}[Y]$

#### 5.4.1 Rechenregeln::

- $\mathbb{E}[a_0 + \sum_{i=1}^n a_i X_i] = a_0 + \sum_{i=1}^n a_i \mathbb{E}[X_i]$
- $Var(X \pm Y) = Var(X) + Var(Y) \pm 2Cov(X, Y)$
- $Var(\sum_{i=1}^n a_i X_i) = \sum_{i=1}^n a_i^2 Var(X_i) + 2 \sum_{i < j} sign(a_i) sign(a_j) Cov(a_i X_i, a_j X_j)$
- $Cov(\sum_{i=1}^n a_i X_i, \sum_{j=1}^m b_j Y_j) = \sum_{i=1}^n \sum_{j=1}^m a_i b_j Cov(X_i, Y_j)$
- $Cov(X, Y) = \mathbb{E}[XY] - \mathbb{E}[Y] \cdot \mathbb{E}[X]$
- $Cov(a + bX, c + dY) = b \cdot d \cdot Cov(X, Y)$
- $Cov(Z + X, Z + Y) = Cov(Z, Z) + Cov(Z, Y) + Cov(X, Z) + Cov(X, Y)$
- $Corr(a + bX, c + dY) = sign(b) \cdot sign(d) \cdot Corr(X, Y)$
- $Corr(X, Y) = +1$  iff  $Y = a + bX$  für  $b > 0$
- $Corr(X, Y) = -1$  iff  $Y = a + bX$  für  $b < 0$

**Wenn  $X, Y$  unabhängig:**

- $Corr(X, Y) = Cov(X, Y) = 0$

#### 5.4.2 Korrelation - Unabhängigkeit:

korreliert	$\Rightarrow$	abhängig
abhängig	$\nRightarrow$	korreliert
unabhängig	$\Rightarrow$	unkorreliert
unkorreliert	$\nRightarrow$	unabhängig
korreliert	$\Leftrightarrow$	Kovarianz $\neq 0$
unkorreliert	$\Leftrightarrow$	Kovarianz = 0
Korrelation = 0	$\Leftrightarrow$	$Cov(X, Y) = 0$

**Ausnahme:** Für 2D-Norm, Ver.: abhängig  $\Leftrightarrow$  korreliert

## 5.5 Zwei-dimensionale Normalverteilung:

Kovarianz-Matrix:

$$\Sigma = \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{Var}(Y) \end{pmatrix}$$

Normalverteilung:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N_2 \left( \begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \Sigma \right)$$

Dichte:

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sqrt{\det\Sigma}} \cdot \exp\left(-\frac{1}{2}(x - \mu_X, y - \mu_Y)\Sigma^{-1} \begin{pmatrix} x - \mu_X \\ y - \mu_Y \end{pmatrix}\right)$$

## 5.6 Lineare Prognose:

Lineare Prognose von Y gestützt mit Ansatz:  $\hat{Y} = a + bX$ :

$$\hat{Y} = \mu_Y + \frac{\text{Cov}(X, Y)}{\text{Var}(X)}(X - \mu_X)$$

$$\mathbb{E}[(Y - \hat{Y})^2] = (1 - \rho_{XY}^2) \cdot \text{Var}(Y)$$

## 6 Grenzwertsätze

**Note:** Die  $n$ -fache Wiederholung eines Zufallsexperimentes ist selber wieder ein Zufallsexperiment.

## 6.1 Independent and identically distributed:

- Ergebnisse im ursprünglichen Experiment  $A_1, \dots, A_n$  sind unabhängig
- $\mathbb{P}[A_1] = \dots = \mathbb{P}[A_n] = \mathbb{P}[A]$  gleiche WK
- Zufallsvariablen  $X_1, \dots, X_n$  sind **unabhängig**
- alle  $X_i$  haben **dieselbe Verteilung**

Mit der i.i.d. Annahme gilt:

1.  $\mathbb{P}[A \cap B] = \mathbb{P}[A] \cdot \mathbb{P}[B]$
2.  $F_{x_1} = F_{x_n} \rightarrow \mathbb{P}(x_1 \leq t) = \mathbb{P}(x_n \leq t)$
3.  $\mathbb{E}[X_1 \cdot X_2] = \mathbb{E}[X_1] \cdot \mathbb{E}[X_2]$

## 6.2 Funktionen von Zufallsvariablen:

Anstelle von  $X_1, \dots, X_n$  werden neue Zufallsvariablen als Funktion der alten gebildet.

- Summe:  $S_n = X_1 + \dots + X_n$
- arithmetisches Mittel:  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{S_n}{n}$  (keine stetige Variable  $\forall n$ )

**Sonderfälle von  $S_n$ :** bei denen die Bestimmung einfach ist:

1. Wenn  $X_i \in \{0, 1\}$  (Bernoulliexperiment), dann ist  $S_n \sim \text{BIN}(n, p)$  mit  $p = \mathbb{P}[X_i = 1]$
2. Wenn  $X_i \sim \text{POI}(\lambda)$ , dann ist  $S_n \sim \text{POI}(n \cdot \lambda)$
3. Wenn  $X_i \sim N(\mu, \sigma^2)$ , dann ist  $S_n \sim N(n \cdot \mu, n \cdot \sigma^2)$
4. Wenn  $X_1, \dots, X_n$  i.i.d und Normalverteilt mit  $\mu_1, \dots, \mu_n$  und  $\sigma_1, \dots, \sigma_n$ , dann ist  $S_n \sim N(\sum \mu, \sum \sigma^2)$

## 6.2.1 Rechenregeln:

Streuung der Summe nimmt zu:

- $\mathbb{E}[S_n] = n \cdot \mathbb{E}[X_i]$
- $\text{Var}(S_n) = n \cdot \text{Var}(X_i) \Rightarrow \sigma_{S_n} = \sqrt{n} \cdot \sigma_{X_i}$

Streuung des arithm. Mittels nimmt ab:

- $\mathbb{E}[\bar{X}_n] = \mathbb{E}[X_i]$
- $\text{Var}(\bar{X}_n) = \text{Var}(X_i)/n \Rightarrow \sigma_{\bar{X}_n} = \sigma_{X_i}/\sqrt{n}$

**Note:**  $\uparrow n \Rightarrow$  "dünnere" Dichte:  $\lim_{n \rightarrow \infty} \text{Var}(\bar{X}_n) = 0$ 

## 6.3 GGZ und ZGWS:

**Theorem: Gesetz der Groessen Zahlen (GGZ)**Seien  $X_1, \dots, X_n$  i.i.d mit  $\mu$   
Arithmetische Mittel strebt gegen den Erwartungswert:

$$\bar{X}_n \rightarrow \mu \quad (n \rightarrow \infty)$$

Dichte strebt gegen die Wahrscheinlichkeit von A:

$$f_n[A] \rightarrow \mathbb{P}[A] \quad (n \rightarrow \infty)$$

**Theorem: Zentraler Grenzwertsatz (ZGWS)**Seien  $X_1, \dots, X_n$  i.i.d. mit  $\mu$  und  $\sigma^2$ , dann für grosse  $n$ :

$$S_n \approx \mathcal{N}(n \cdot \mu, n \cdot \sigma^2)$$

$$\bar{X}_n \approx \mathcal{N}(\mu, \sigma^2/n)$$

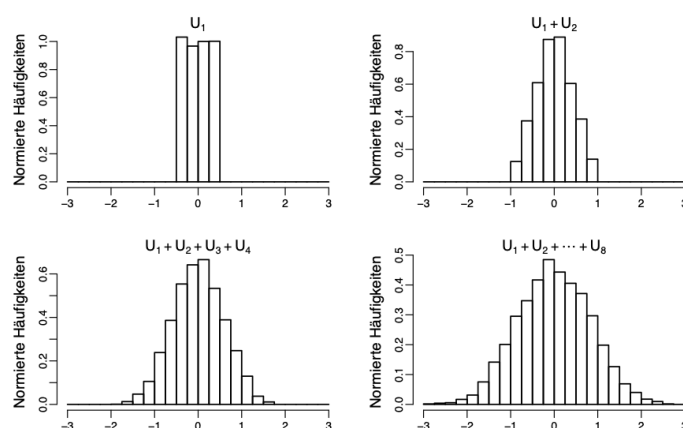
**Note:**  $Z = \frac{1}{\sqrt{n}} \frac{S_n - n\mu}{\sigma} \sim \mathcal{N}(0, 1) \Rightarrow (1 - \alpha) \times \% \text{ Konfidenzintervall:}$ 

$$1 - \alpha = \mathbb{P}\left(\underbrace{-z_{1-\frac{\alpha}{2}} \leq Z \leq z_{1-\frac{\alpha}{2}}}_{\text{Intervall}}\right)$$

**Theorem: Chebychev Ungleichung**Sei  $X$  eine Zufallsvariable mit Erwartungswert  $\mu$  und endlicher Varianz  $\sigma$ , Dann gilt  $\forall k > 0$ :

$$\mathbb{P}(|\bar{X}_n - \mu| \geq k) \leq \frac{\sigma^2}{k^2} \text{ oder } \mathbb{P}(|X - \mu| < k) \geq 1 - \frac{\sigma^2}{k^2}.$$

Mit dieser ist man stets auf der sicheren Seite, dafür aber meistens ziemlich grob.



**Example: Casinò Roulette**

In ein Casinò mit 25 Roulette (37 Zahlen),  $10^4 \frac{\text{"rot"}}{\text{month}}$ .

1. Erwartete Gewinn des Casinò?
2. Wahrscheinlichkeit das Casinò am ende Monat mehr als 4000.- Gewinn hat?
3. Wieviel mal muss 1.- auf "rot" gesetzt damit durchschnittliche Gewinn Casinò per Wette mit 95% Wahrscheinlichkeit 2 cent oder mehr ist?

Solution:

1. Sei  $X_i$  das Gewinn des Casinò bei i-ten Spiel:

$$\begin{cases} \mathbb{P}(X_i = 1) = \frac{19}{37} \\ \mathbb{P}(X_i = -1) = \frac{18}{37} \end{cases} \quad \begin{cases} \mathbb{E}(X_i) = \frac{19}{37} - \frac{18}{37} = \frac{1}{37} \\ \text{Var}(X_i) = \mathbb{E}(X_i^2) - \mathbb{E}(X_i)^2 = 1 - \frac{1}{37^2} \end{cases}$$

$$\text{Gewinn Casinò} = S_n \Rightarrow \mathbb{E}(S_1) = \mathbb{E}(X_1) \cdot n$$

2.  $S_n \sim \mathcal{N}(\mathbb{E}(X_1) \cdot n, \text{Var}(X_1) \cdot n) \Rightarrow \mathbb{P}(S_n > 4000) = \dots$  normalisieren
3.  $\mathbb{P}(\bar{X}_n > 0.02) \geq 0.95$ , mit  $\bar{X}_n \sim \mathcal{N}(\mathbb{E}(X_1), \frac{\text{Var}(X_1)}{n})$

**7 Parameterschätzungen****7.1 Wahl der Verteilungsfamilie (QQ-Plot):**

**Q-Q-Plot:** "Quantil-Quantil-Plot", es wird das theoretische Quantil gegenüber dem empirischen Quantil aufgetragen. Aussage möglich, wie gut die Daten dem Modell entsprechen. Wir definieren:

$$\alpha_k = \frac{k - 0.5}{n}, \quad k = 1, \dots, n$$

die entsprechenden empirischen  $(\alpha \times 100)\%$  - Quantile.

**Note:** Die Beobachtung  $x_{(k)}$  gerade das entsprechende empirische Quantil. Das entsprechende (theoretische)  $(\alpha \times 100)\%$  - Quantile ist gegeben durch  $F^{-1}(\alpha_k)$ .

Falls die Daten wirklich von unserer Modellverteilung generiert wurden, sollten die empirischen Quantile ungefähr den theoretischen Quantilen entsprechen (**Gerade auf ungefähr Winkelhalbierende!**).

- **Vorteil** von QQ-Plot: die Abweichungen am Rand der Verteilung sind einfacher zu erkennen als z.B. bei einem Histogramm.
- **Nachteil** von QQ-Plot: die Parameter der Modellverteilung schon kennen müssen, sonst können wir die (theoretischen) Quantile nicht berechnen!

**7.1.1 Exponential QQ-Plot:**

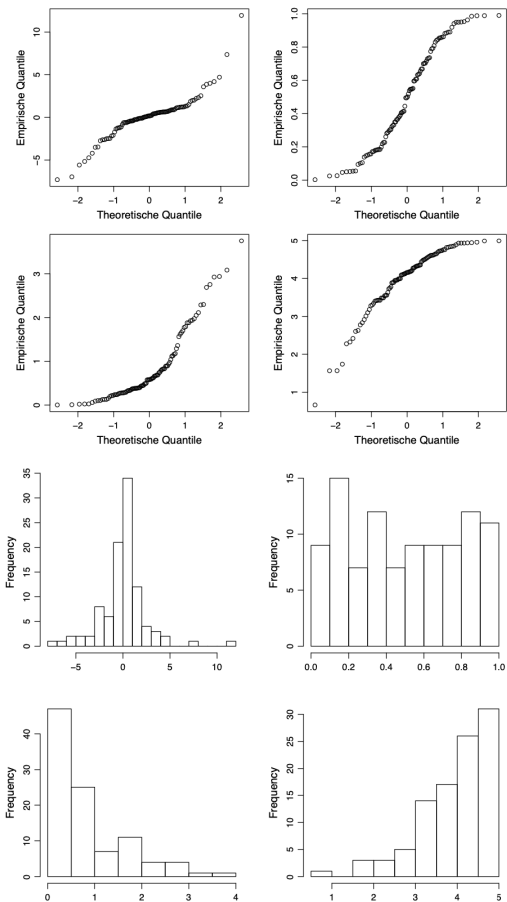
Angenommen wird ein  $F$  gemäss 3.4: im Plot ist zu sehen eine Gerade mit Steigung  $\frac{1}{\lambda}$  durch Nullpunkt.

**7.1.2 Normalverteilt QQ-Plot:**

QQ-Plot, bei dem die Modellverteilung  $F$  die Standardnormalverteilung  $\mathcal{N}(0, 1)$  ist. Das Plot (wenn Normalverteilt) ist eine Gerade mit Steigung  $\sigma$  und y-Achsenabschnitt  $\mu$ . Falls der Normalplot keine schöne Gerade zeigt, kann man trotzdem etwas über die zugrunde liegende Verteilung sagen:

- **Langschwanzigen Verteilung** (verglichen mit einer Normalverteilung): die empirischen Quantile in einem Bereich zwar auf einer Geraden liegen, aber im oberen Bereich nach oben und im unteren Bereich nach unten "wandern". Der QQ-Plot  $\rightarrow$  "invertiertes S". Das bedeutet, dass das empirische 99% Quantil viel grösser ist als man von der Normalverteilung erwarten würde. (1% grössten Werte der (empirischen) Verteilung sind grösser als von der Normalverteilung erwartet).

- **Kurzschnanzigen Verteilung** (verglichen mit einer Normalverteilung): gleich umgekehrt wie beim Langschwanzigen Verteilung: der QQ-Plot zeigt dann eine "S-Form".
- **Schiefe Verteilung** (verglichen mit einer Normalverteilung): zeigen sich durch "durchgebogene" Kurven. Bei recht schiefer Verteilung (Plot unten rechts) ist der empirische Median grösser als das arithmetische Mittel (umgekehrt beim links-schiefer)



**Note:** Im Bild stehen Beispiele für QQ-Plots von langschwanzigen (oben links), kurzschnanzigen (oben rechts) und schiefen Verteilungen (unten).

**7.2 Methode der Parameterschätzung:**

Die Verteilung von  $X_i$  sei bekannt bis auf einen unbekannten Parameter  $\theta$ , dabei kann  $\theta$  auch mehrere Komponenten haben.

**7.2.1 Momentenmethode:**

Das k-te Moment von  $X$  ist definiert als:

$$\mu_k = \mathbb{E}[X^k]$$

Das k-te empirische Moment von  $x_1, \dots, x_n$  gegeben ist durch:

$$m_k = \hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

**Achtung:** Momentenmethode ist nicht eindeutig und nicht optimal und kann manchmal auch unsinnige Resultate liefern.

**Vorgehen: Momentenmethode**

1. Unbekannte Parameter  $\theta$  als Funktion der Momente  $\mu_k = \mathbb{E}(X^k)$  schreiben
2. Vergleiche wahre  $\mu_k$  durch empirische Momente  $m_k$  und löse für  $\hat{\theta}_i$

**Note:** Binomial:  $\theta = p$ , Poisson:  $\theta = \mu$ , Standardnormalverteilung:  $\theta = (\mu, \sigma^2)^T$

**Example: Anteil der kranken Population**

Sei  $X_i$  eine Zufallsvariable, die 1 ist, falls die i-te Testperson positiv getestet ist und sonst 0. Sei  $A_i$  das Ereignis, dass die i-te Testperson die Krankheit bereits hatte. Gegeben sei:

- $m_1 = \frac{\# \text{Leute Positiv bei Test}}{\# \text{Leute}}$
- $p_1 = \mathbb{P}(X_i = 1 | A_i)$  und  $p_2 = \mathbb{P}(X_i = 1 | A_i^c)$
- $\mathbb{P}(A_i) = q$

Gesucht ist das Schätzer  $q$  der Anteil der Kranken Leuten:

$$\mathbb{E}(X_i) = 1 \cdot \mathbb{P}(X_i = 1) = p_1 q + p_2 (1 - q)$$

Vergleichen von  $\mathbb{E}(X_i)$  und  $m_1$ , das erste empirische Moment liefert die Lösung.

**7.2.2 Maximum-likelihood Methode (MLE):**

Sei die Maximum-Likelihood definiert als:

$$\hat{\theta} = \operatorname{argmax}_{\theta} L(\theta) = \operatorname{argmax}_{\theta} l(\theta)$$

mit

$$L(\theta) = p_{X_1, \dots, X_n | \theta}(x_1 \dots x_n) = \prod_{i=1}^n p_X(x_i | \theta) = p_X(x_1 | \theta) \cdots p_X(x_n | \theta)$$

und (log- Likelihoodfunktion)

$$l(\theta) = \ln(L(\theta)) = \sum_{i=1}^n \ln(p_X(x_i | \theta)) = \ln(p_X(x_1 | \theta)) + \cdots + \ln(p_X(x_n | \theta))$$

**Note:** Für stetige funktionen:  $p_X(x_i | \theta) \Rightarrow f_X(x_i | \theta)$

**Note:** Bei Bernoulli:  $\hat{p} = \frac{\sum x_i}{n}$ , bei POI:  $\hat{\lambda} = \frac{\sum x_i}{n}$ , bei  $UNI[0, \theta] : \hat{\theta} = \max\{x_1, \dots, x_n\}$

**7.2.3 Allgemeine Schätzer für Erwartungswert und Varianz:**

Gegeben seien  $x_1, \dots, x_n$  i.i.d Beobachtungen von einer ZV  $X$ . Die Schätzer lauten:

$$\hat{\mu}_X = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}_X^2 = S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Ein Schätzer  $\hat{\theta}$  ist auch eine Zufallsvariable und heisst **erwartungstreu**, wenn  $\mathbb{E}(\hat{\theta}) = \text{wahrer Parameterwert}$ .

Wir haben also, dass

- $\mathbb{E}(\hat{\mu}_X) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \frac{1}{n} \cdot n \cdot \mu = \mu \rightarrow \text{erwartungstreu!}$
- $\mathbb{E}(\hat{\sigma}_X^2) = \sigma_X^2 \rightarrow \text{erwartungstreu!}$
- $\text{Var}(\hat{\mu}_X) = \frac{1}{n} \sigma_X^2 \rightarrow \text{nicht erwartungstreu!}$

**Example:  $X \sim \text{BIN}(n, p)$  Schätzer**

Schätzer  $\hat{p} = \frac{x}{n}$  ( $x$ : gemessene Erfolge)

$$\mathbb{E}(\hat{p}) = \mathbb{E}\left(\frac{x}{n}\right) = \frac{1}{n} \mathbb{E}(x) = \frac{1}{n} \cdot np = p$$

$\rightarrow$  erwartungstreu!

**8 Statistische Tests und Vertrauensintervalle für eine Stichprobe****8.1 Das Testproblem:**

Nullhypothese:  $H_0 : p = p_0$

Alternativen:

- $H_A : p \neq p_0$  (zweiseitig)
- $H_A : p > p_0$  (einseitig nach oben, rechtsseitig)
- $H_A : p < p_0$  (einseitig nach unten, linksseitig)

		Entscheidung	
		$H_0$	$H_A$
Wahrheit	$H_0$	Kein Fehler	Fehler 1. Art
	$H_A$	Fehler 2. Art	Kein Fehler

**Fehler 1. Art:** Verwerfen Nullhypothese, obwohl sie richtig ist.

$$\mathbb{P}(\text{Fehler 1. Art}) = \mathbb{P}_{p_0}(X \geq c) \leq \alpha$$

**Fehler 2. Art:** kein Verwerfen Nullhypothese, obwohl sie falsch ist.

$$\mathbb{P}(\text{Fehler 2. Art}) = \beta(\theta) \quad (\text{siehe 8.2.1})$$

**Vorgehen: Statistischen Tests**

1. Wähle ein geeignetes Modell für die Daten und ein Signifikanzniveau  $\alpha$ .
2. Lege die Nullhypothese  $H_0 : \theta = \theta_0$  fest.  $\theta$  bezeichnet hier allgemein einen Parameter in einem Modell.
3. Spezifiziere die Alternativhypothese:

$$\begin{aligned} H_A : \theta &\neq \theta_0 \text{ ("zweiseitig")} \\ \theta &> \theta_0 \text{ ("einseitig nach oben")} \\ \theta &< \theta_0 \text{ ("einseitig nach unten")} \end{aligned}$$

4. Konstruiere den Verwerfungsbereich  $K$  für  $H_0$ , so dass gilt:

$$\mathbb{P}(\text{Fehler 1. Art}) = \leq \alpha$$

5. Betrachte, ob die Beobachtung  $x$  in den Verwerfungsbereich fällt.

**8.2 Eigenschaften von statistischen Tests:****8.2.1 Macht eines Tests:**

Ein statistischer Test kontrolliert direkt die Wahrscheinlichkeit eines Fehlers 1. Art durch das Signifikanzniveau  $\alpha$ :

$$\mathbb{P}(\text{Fehler 1. Art}) = \mathbb{P}(\text{Test verwirft } H_0, \text{ obwohl } H_0 \text{ stimmt}) \leq \alpha$$

**Note:** Bei stetigen Verteilungen ist obige Ungleichung eine Gleichung, da wir das Niveau exakt kontrollieren können.

Wahrscheinlichkeit eines **Fehler 2. Art:**

$$\beta(\theta) = \mathbb{P}(\text{Test akzeptiert } H_0 \text{ obschon ein } \theta \in H_A \text{ stimmt})$$

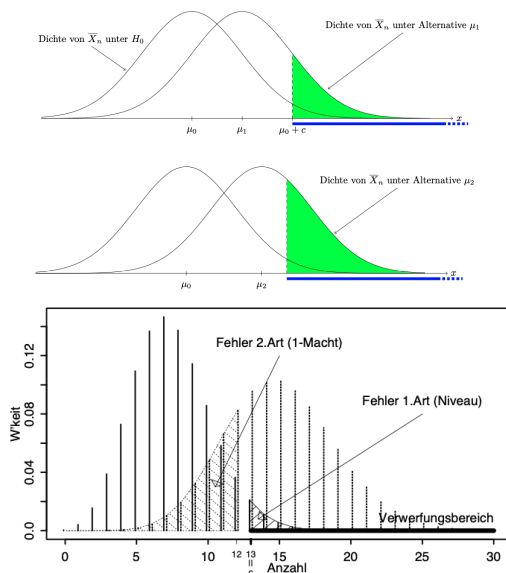
Die **Macht** eines Testes ist die Wahrscheinlichkeit, dass dieser für ein  $p \neq p_0$  richtig verwirft:

$$\text{Macht} = 1 - \beta(\theta) = 1 - \mathbb{P}(\text{Fehler 2. Art})$$

**Note:**

- Wenn Macht  $\uparrow$ ,  $\alpha \uparrow$ ,  $\#n \uparrow$ ,  $\mathbb{P}(\text{Fehler 1. Art}) \uparrow$ , grosse  $K \uparrow$ ,  $\mathbb{P}(H_0 \text{ verwerfen}) \uparrow$ .

- Je kleiner der Unterschied zwischen  $p_0$  und  $p$ , desto kleiner die **Macht** und desto schwieriger ist es für den Test richtig zu entscheiden.



### 8.2.2 P-Wert:

P-Wert = Wahrscheinlichkeit, unter der Nullhypothese einen mindestens so extremen Wert der Teststatistik zu beobachten (in Richtung der Alternative), wie der aktuell beobachtete.

$$\text{P-Wert} < \alpha \rightarrow H_0 \text{ verwerfen}$$

**Note:**

- P-Wert ist grosser bei beidseitig Hypothese als bei einseitig.
- Verglichen mit dem reinen Testentscheid enthält der p-Wert aber mehr Information, da man direkt sieht, "wie stark" die Nullhypothese verworfen wird.
- P-Wert von den Daten abhängt  $\rightarrow$  zufällig  $\rightarrow$  P-Wert  $\sim \text{UNI}(0, 1)$
- Der P-Wert ist insbesondere nicht die Wahrscheinlichkeit, dass die Nullhypothese stimmt!
- Ein (sehr) kleiner P-Wert bedeutet nicht zwangsläufig, dass ein fachlich relevantes Resultat gefunden wurde, da der P-Wert nichts über eine Effektgrösse aussagt.
- Man muss wissen, ob der Test einseitig oder zweiseitig ist.

### 8.2.3 Multiples Testen:

Wir schreiben  $H_{0,j}$  für die j-te Nullhypothese,  $j = 1, \dots, m$ . Mit  $m$  bezeichnen wir also die Anzahl Tests. Wenn wir annehmen, dass alle Nullhypothesen stimmen und alle Tests **unabhängig** voneinander sind, dann haben wir:

$$\begin{aligned} \mathbb{P}(\geq \text{ein } H_{0,j} \text{ verworfen}) &= 1 - \mathbb{P}(\text{Kein } H_{0,j} \text{ verworfen}) \\ &= 1 - \mathbb{P}\left(\bigcap_{j=1}^m \{H_{0,j} \text{ nicht verworfen}\}\right) \\ &= 1 - \prod_{j=1}^m \mathbb{P}(H_{0,j} \text{ nicht verworfen}) \\ &= 1 - (1 - \alpha)^m \end{aligned}$$

Wenn wir **keine Unabhängigkeit** annehmen, dann:

$$\begin{aligned} \mathbb{P}(\text{Mind. ein } H_{0,j} \text{ verworfen}) &= \mathbb{P}\left(\bigcup_{j=1}^m \{H_{0,j} \text{ verworfen}\}\right) \\ &= \sum_{j=1}^m \mathbb{P}(H_{0,j} \text{ verworfen}) \\ &= \alpha \cdot m \end{aligned}$$

### Theorem: Bonferroni-Korrektur

Gegeben seien  $m$  Tests wo wir keine Unabhängigkeit annehmen: für jeden einzelnen Test definieren wir das strikere Niveau  $\alpha^* = \frac{\alpha}{m}$ , dann:

$$\mathbb{P}(\text{Mind. ein } H_{0,j} \text{ verworfen}) \leq \alpha$$

**Note:** Universell gültig. Der Nachteil ist, dass man ein sehr striktes Niveau verwenden muss und daher Macht verliert im Gegensatz zu anderen Korrektur-Methoden. In der Praxis sollte man nur einen definierten Test durchführen, oder falls mehreren Tests, eine entsprechende Korrektur-Methode anwenden.

### 8.3 Vertrauens- /Konfidenzintervalle:

Ein Vertrauensintervall (oder Konfidenz-)  $I$  für den Parameter  $\theta$  zum Niveau  $1 - \alpha$  besteht aus allen Parameterwerten zum Signifikanzniveau  $\alpha$  die vertraglich sind.

**Note:** Das Vertrauensintervall ist zufällig (hängt indirekt von unseren Beobachtungen ab, die wir als Realisierungen von Zufallsvariablen betrachten). Für andere Realisierungen werden wir also ein (leicht) anderes Vertrauensintervall erhalten!

$$\mathbb{P}(I \ni \theta) = 1 - \alpha$$

Hier ist  $I$  zufällig und  $\theta$  fix. Das heisst, wenn wir ein Experiment viele Male wiederholen, dann fangt das Vertrauensintervall den wahren (unbekannten) Parameter im Schnitt in  $(1 - \alpha) \times 100\%$  der Fälle ein.

Die Vertrauensintervalle enthalten auch eine Angabe über die Genauigkeit der Parameterschätzung!

$$\text{Testentscheid} < \text{P-Wert} < \text{Vertrauensintervall}$$

wobei sich die Relation " $<$ " auf den Informationsgehalt bezieht.

**Zweiseitiges  $(1 - \alpha)$  Vertrauensintervall allgemein:**

$$I = \hat{\theta} \pm \left(1 - \frac{\alpha}{2}\right)_{\text{Quantil}} \cdot \sqrt{\text{Var}(\hat{\theta})}$$

**Rechtsseitig ( $\theta_A > \theta_0$ ):**

$$I = \left[ \hat{\theta} - (1 - \alpha)_{\text{Quantil}} \cdot \sqrt{\text{Var}(\hat{\theta})}, \infty \right)$$

**Linksseitig ( $\theta_A < \theta_0$ ):**

$$I = \left( -\infty, \hat{\theta} + (1 - \alpha)_{\text{Quantil}} \cdot \sqrt{\text{Var}(\hat{\theta})} \right]$$

#### 8.3.1 Andere Verteilungen Vertrauensintervalle:

- $X \sim \text{Poi}(\lambda) \approx \mathcal{N}(\lambda, \lambda)$ ,  $\hat{\theta} = \lambda$ :

$$I = \lambda \pm \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \sqrt{\lambda}$$


- Hypergeometrisch (Urnenmodell ohne Zurücklegen),  $n$  gross,  $N$  sehr gross:

$$I = p \pm z \left(1 - \frac{\alpha}{2}\right) \sqrt{\frac{p(1-p)}{n}} \sqrt{\frac{N-n}{N-1}}$$



### 8.3.2 Statistische Signifikanz und fachliche Relevanz:

Nehmen wir an, dass Abweichungen bis  $\delta$  vom  $\mu_0$  keine Rolle spielen, also nicht relevant sind. Wir haben also einen **“irrelevanten Bereich”**, der von  $\mu_0 - \delta$  bis  $\mu_0 + \delta$  geht. Ausserhalb sprechen wir vom **“Relevanzbereich”**:



### 8.4 Binominalverteilte Test:

Wir haben, dass:

- $H_0 : p = p_0$
- $H_A : p > p_0$

**Einseitig Test:** Unter  $H_0$  ist die Wahrscheinlichkeit, die Nullhypothese fälschlicherweise abzulehnen (d.h. die Wahrscheinlichkeit, einen Fehler 1. Art zu begehen) gegeben durch:

$$\mathbb{P}(\text{Fehler 1. Art}) = \mathbb{P}_{p_0}[X \geq c] = \sum_{k=c}^n \binom{n}{k} p_0^k (1-p_0)^{n-k}$$

**Note:**  $\mathbb{P}(\text{Fehler 2. Art}) = 1 - \sum_{k=c}^n \binom{n}{k} p_0^k (1-p_0)^{n-k}$

Bei **Zweiseitige Alternative**  $H_A : p \neq p_0$  verwerfen die Nullhypothese für  $c_2 \leq x \leq c_1$  wenn:

- $\mathbb{P}_{p_0}[X \leq c_1] = \sum_{k=0}^{c_1} \binom{n}{k} p_0^k (1-p_0)^{n-k} \leq \frac{\alpha}{2}$  and
- $\mathbb{P}_{p_0}[X \geq c_2] = \sum_{k=c_2}^n \binom{n}{k} p_0^k (1-p_0)^{n-k} \leq \frac{\alpha}{2}$

die Verwerfungsbereich ist also gegeben in diesen Fall bei:

$$K = \{0, 1, 2, \dots, c_1\} \cup \{c_2, c_2 + 1, \dots, n\}$$

**Note:** Bin-Verteilung nur bei  $p = 0.5$  symmetrisch!

#### Example: Muntze Wurf

Ich werfe eine Muntze 10 Mal und bekomme 8 mal Kopf,  $\alpha = 0.05$ .

Wir wissen, dass  $H_0 : X \sim \text{BIN}(10, 0.5)$

- $\mathbb{P}_{H_0}(X = 9) + \mathbb{P}_{H_0}(X = 10) < \alpha$
- P-Wert =  $\mathbb{P}_{H_0}(X = 8) + \mathbb{P}_{H_0}(X = 9) + \mathbb{P}_{H_0}(X = 10) > \alpha \Rightarrow K = \{9, 10\}$

Macht wenn in der Tat  $p = 0.75 \rightarrow H_{\text{wahr}} : X \sim \text{BIN}(10, 0.75)$

$$\mathbb{P}(X \in K) = \mathbb{P}(X \geq 9) = \mathbb{P}_{H_{\text{wahr}}}(X = 9) + \mathbb{P}_{H_{\text{wahr}}}(X = 10) = 0.24$$

Die Macht der Test ist also  $0.24 = \mathbb{P}(\text{significant Testresultat})$

Wenn  $n$  gross,  $X \sim \text{Bin}(n, p) \approx \mathcal{N}(np, np(1-p))$ .

Das  $(1-\alpha) \times 100\%$  **Vertrauensintervall** ist gegeben als:

$$I = \hat{p} \pm \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \sqrt{\hat{p}(1-\hat{p}) \frac{1}{n}}, \hat{p} = \frac{x}{n}, x = \text{gemessene Erfolge}$$

**Note:**  $\text{Var}(\hat{p}) = \text{Var}\left(\frac{x}{n}\right) = \frac{1}{n^2} \text{Var}(X) = \frac{\hat{p}(1-\hat{p})}{n}$

### 8.5 Tests Stichprobe bei normalverteilten Daten:

Gegeben seien  $n$  voneinander unabhängige Beobachtungen  $x_1, \dots, x_n$  einer ZV  $X \sim \mathcal{N}(\mu, \sigma^2)$ . Als Schätzer für die unbekannten Parameter der Normalverteilung betrachten wir die erwartungstreuen Schätzer:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}^2 = S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \hat{\mu})^2$$

Wir fixieren je nach Problemstellung ein  $\mu_0 \in \mathbb{R}$  unter Nullhypothese  $H_0 : \mu = \mu_0$  gegen eine der möglichen Alternativen:

$$H_A : \mu \neq \mu_0 \text{ ("zweiseitig")}$$

$$\mu > \mu_0 \text{ ("einseitig nach oben")}$$

$$\mu < \mu_0 \text{ ("einseitig nach unten")}$$

#### 8.5.1 Z-Test:

Das Z-Test ist das Machtigste Test die wir machen können. Wir nehmen, dass  $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ ,  $\mu$  unbekannt, aber  $\sigma$  bekannt.


#### Vorgehen: Z-Test

Wir definieren also die **Teststatistik** als:

$$Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} = \frac{\text{beobachtet} - \text{erwartet}}{\text{geschätzter Standardfehler}} \sim \mathcal{N}(0, 1)$$

Wir verwerfen  $H_0$  falls:

1.  $H_A : \mu \neq \mu_0$ :  
 $|Z| \geq z_{1-\frac{\alpha}{2}} \iff Z \in K = (-\infty, -z_{1-\frac{\alpha}{2}}] \cup [z_{1-\frac{\alpha}{2}}, \infty)$
2.  $H_A : \mu > \mu_0$ :  
 $Z \geq z_{1-\alpha} \iff Z \in K = [z_{1-\alpha}, \infty)$
3.  $H_A : \mu < \mu_0$ :  
 $Z \leq z_{\alpha} = -z_{1-\alpha} \iff Z \in K = (-\infty, z_{\alpha}] = (-\infty, -z_{1-\alpha}]$



**Note:**

- $z_{1-\alpha} = \Phi^{-1}(1-\alpha) = -\Phi^{-1}(\alpha)$
- Im Bild: Dichtefunktion der Teststatistik  $Z$  mit Verwerfungsbereich (blau) des zweiseitigen Z-Tests zum Niveau  $\alpha$ .
- $\mathbb{P}(\text{Fehler 1. Art}) = \mathbb{P}(|Z| \geq z_{1-\frac{\alpha}{2}}) = \alpha$
- Wenn wahre Wert  $\mu = \mu_{\text{wahr}} \rightarrow Z \sim \mathcal{N}\left(\frac{\mu_{\text{wahr}} - \mu_0}{\sigma/\sqrt{n}}, 1\right) = \mathcal{N}(\tilde{\mu}, 1)$

$(1-\alpha) \times 100\%$  **Vertrauensintervall** für  $\mu_0$  ist gegeben durch:

$$I = \bar{X}_n \pm \frac{\sigma}{\sqrt{n}} \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)$$

Diese hat also die Form:

$$\text{Schätzung} \pm \text{Quantil} \cdot (\text{geschätzter Standardfehler})$$

**Macht:** Sei  $K$  das Verwerfungsbereich von  $Z$ . Wenn in Wahrheit die Daten mit  $\mu_{\text{wahr}}$  zentriert sind definieren wir die neue Teststatistik als:

$$Z_A = \frac{\bar{X}_n - \mu_{\text{wahr}}}{\sigma/\sqrt{n}} = Z - \frac{\mu_{\text{wahr}} - \mu_0}{\sigma/\sqrt{n}}$$


So ist die Macht der  $Z$ -Test gegeben durch (am bsp für einseitig unten Test):

$$\begin{aligned} \text{Macht} &= \mathbb{P}(Z \in K | H_A) = \\ &= \mathbb{P}(Z \leq z_\alpha | H_A) = \mathbb{P}(Z_A \leq z_\alpha - \frac{\mu_{\text{wahr}} - \mu_0}{\sigma/\sqrt{n}} | H_A) = \\ &= \Phi(z_\alpha - \frac{\mu_{\text{wahr}} - \mu_0}{\sigma/\sqrt{n}}) = \Phi(z_\alpha - \tilde{\mu}) \end{aligned}$$

### 8.5.2 t-Test:

Das t-Test ist wenig mächtiger als das Z-Test. Wir nehmen an, dass  $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ ,  $\mu, \sigma$  unbekannt.

**Note:** Die  $t$ -Verteilung ist wie die Standardnormalverteilung symmetrisch um 0, hat aber eher die Tendenz, grosse Werte anzunehmen (langschwanziger).



### Vorgehen: t-Test

Die realisierte **Teststatistik** ist:

$$\tilde{T} = \frac{\bar{X}_n - \mu_0}{S_n/\sqrt{n}} \sim t_{n-1}, \quad \text{unter } H_0, n-1 \text{ DOF}$$

Wir verwerfen  $H_0$  falls:

$$1. H_A : \mu \neq \mu_0:$$

$$|\tilde{T}| \geq t_{n-1, 1-\frac{\alpha}{2}} \iff \tilde{T} \in K = (-\infty, -t_{n-1, 1-\frac{\alpha}{2}}] \cup [t_{n-1, 1-\frac{\alpha}{2}}, \infty)$$

$$2. H_A : \mu > \mu_0:$$

$$\tilde{T} \geq t_{n-1, 1-\alpha} \iff \tilde{T} \in K = [t_{n-1, 1-\alpha}, \infty)$$

$$3. H_A : \mu < \mu_0:$$

$$\tilde{T} \leq t_{n-1, \alpha} = -t_{n-1, 1-\alpha} \iff \tilde{T} \in K = (-\infty, \underbrace{t_{n-1, \alpha}}_{=-t_{n-1, 1-\alpha}}]$$

$(1 - \alpha) \cdot 100\%$  **Vertrauensintervall** für  $\mu_0$  ist gegeben durch:

$$I = \bar{X}_n \pm \frac{S_n}{\sqrt{n}} t_{n-1, 1-\frac{\alpha}{2}}$$

**Zweiseitig P-Wert:**

- P-Wert =  $2 \cdot \mathbb{P}(T \geq \tilde{T})$   
Note: Wenn P-Wert  $> 2 \cdot \mathbb{P}(T \geq t_{n-1, 1-\frac{\alpha}{2}}) = \alpha$  kann die Nullhypothese nicht verworfen werden.

- $\tilde{T} = t_{n-1, 1-\frac{\alpha}{2}}$ , löse für  $\alpha$  durch Interpolation  $\Rightarrow \alpha = \text{P-Wert}$

**Macht:** Sei  $K$  das Verwerfungsbereich von  $\tilde{T}$ . Wenn in Wahrheit die Daten mit  $\mu_{\text{wahr}}$  zentriert sind definieren wir die neue Teststatistik als:

$$\tilde{T}_A = \frac{\bar{X}_n - \mu_{\text{wahr}}}{S_n/\sqrt{n}} = \tilde{T} - \frac{\mu_{\text{wahr}} - \mu_0}{S_n/\sqrt{n}}$$

So ist die Macht der  $t$ -Test gegeben durch (am bsp für zweiseitig Test):

$$\begin{aligned} \text{Macht} &= \mathbb{P}(\tilde{T} \in K | H_A) = \\ &= \mathbb{P}(\tilde{T} > t_{n-1, 1-\frac{\alpha}{2}} | H_A) + \mathbb{P}(\tilde{T} < -t_{n-1, 1-\frac{\alpha}{2}} | H_A) = \\ &= \mathbb{P}(\tilde{T}_A > t_{n-1, 1-\frac{\alpha}{2}} - \frac{\mu_{\text{wahr}} - \mu_0}{S_n/\sqrt{n}} | H_A) + \dots \end{aligned}$$

**Note:** Die Wahrscheinlichkeit  $\mathbb{P}(\tilde{T}_A > \dots | H_A) = 1 - \mathbb{P}(\tilde{T}_A \leq \dots | H_A)$  lese ich von der Tabelle der  $t$ -Verteilung.

### 8.6 Tests Stichprobe bei nicht normalverteilten Daten:

In der Praxis sind unsere Messdaten nicht immer normalverteilt. Auch für diese Situationen gibt es entsprechende Tests mit weniger starken Annahmen.

#### 8.6.1 Vorzeichen-Test:

Wir betrachten allgemeiner Beobachtungen  $x_1, \dots, x_n$  von i.i.d ZV  $X_1, \dots, X_n \sim \mathcal{F}(\mu)$ , wobei  $\mathcal{F}$  eine beliebige stetige Verteilung mit Median  $\mu$  ist.

Wir stellen die Null- und Alternativhypothese bzgl. dem Median:

- $H_0 : \mu = \mu_0$
- $H_A : \mu \neq \mu_0$

**Note:** Bei symmetrischen Verteilungen entspricht der Median dem Erwartungswert. Das Vorzeichen Test hat auch eine sehr tiefe Macht!

Wenn  $\mu = \mu_0$  tatsächlich stimmt, dann beobachten wir mit 50% Wahrscheinlichkeit einen Wert grösser als  $\mu_0$  (Definition des Medians). Wenn wir also allzu viele (oder zu wenige) Werte haben, die grösser als  $\mu_0$  sind, dann spricht dies gegen die Nullhypothese und für die Alternative.

### Vorgehen: Vorzeichen-Test

Wir betrachten:

$$Q = \#\text{Positive } X_i - \mu_0$$

Die Anzahl positiver Vorzeichen  $Q$ , folgt unter  $H_0$  einer  $BIN(n, 0.5)$ -Verteilung  $\rightarrow H_0 : p_0 = 0.5$

Wir verwerfen  $H_0$  falls:

$$1. H_A : p_A \neq 0.5:$$

$$\text{P-Wert} = \mathbb{P}(X \leq n-Q) \cup \mathbb{P}(X \geq Q) \stackrel{p_0=0.5}{=} 2 \cdot \mathbb{P}(X \geq Q) < \alpha$$

$$2. H_A : p_A > 0.5:$$

$$\text{P-Wert} = \mathbb{P}(X \geq Q) = \sum_{i=Q}^n BIN(n, 0.5)(i) < \alpha$$

$$3. H_A : p_A < 0.5:$$

$$\text{P-Wert} = \mathbb{P}(X \leq Q) = \sum_{i=0}^Q BIN(n, 0.5)(i) < \alpha$$

**Note:** Bin-Verteilung nur bei  $p = 0.5$  symmetrisch!

**Macht:** siehe Beispiel 8.4



## 8.6.2 Wilcoxon-Test:

Kompromiss: setzt weniger voraus als t-Test, nutzt Daten aber besser aus als Vorzeichen-Test. Wir betrachten allgemeiner Beobachtungen  $x_1, \dots, x_n$  von i.i.d ZV  $X_1, \dots, X_n \sim \mathcal{F}(\mu)$ , wobei  $\mathcal{F}$  eine beliebige stetige **symmetrische** Verteilung mit Median  $\mu$  ist.

Wir stellen die Null- und Alternativhypothese bzgl. dem Median:

- $H_0 : \mu = \mu_0$
- $H_A : \mu \neq \mu_0$

## Vorgehen: Wilcoxon-Test

1. Wir definieren:  $U_i = X_i - \mu_0$
2. Range bilden:  $\text{Rang}(|U_i|) = k$   
**Note:**  $k = 1$  bedeutet, dass  $|U_i|$  den kleinsten Wert unter  $|U_1|, \dots, |U_n|$  hat.  
**Achtung:** Wenn zwei  $|U_i|$  gleich sind, teilt man die Range auf (siehe unten)
3.  $V_i$  ist Indikator, ob  $U_i$  positiv ist:  $\begin{cases} V_i = 1, & \text{falls } U_i > 0 \\ V_i = 0, & \text{falls } U_i < 0 \end{cases}$
4. Verwerfung der Nullhypothese falls  $W$  zu gross, zu klein oder beides ist (Tabellen).

$$W = \sum_{i=1}^n \text{Rang}(|U_i|) \cdot V_i$$

## Note:

- Der Wilcoxon-Test halt das Niveau  $\alpha$  exakt, falls  $\mathcal{F}$  um 0 symmetrisch und  $x_i$  i.i.d ist. Beim t- Test wird zwar das Niveau auch ungefahr eingehalten, falls die Daten nicht ganz normalverteilt sind, aber die Wahrscheinlichkeit ein Fehler 2.Art von t-Test ist oft viel grosser als Fehler 2.Art von Wilcoxon-Test
- Der Wilcoxon-Test ist in der Praxis dem t- oder Vorzeichen-Test vorzuziehen, da Daten meist nicht Normalverteilt sind.

## Example: Gleiche Range bei Wilcoxon-Test

Wenn wir diese Folge von Beobachtungen hatten:

$$|X_3| < |X_2| = |X_5| < |X_6| < |X_1| = |X_4| = |X_8| < |X_7|$$

Dass wurde:

- $\text{Rang}(|X_3|) = 1$
- $\text{Rang}(|X_2|) = \text{Rang}(|X_5|) = \frac{2+3}{2} = 2.5$
- $\text{Rang}(|X_6|) = 4$
- $\text{Rang}(|X_1|) = \text{Rang}(|X_4|) = \text{Rang}(|X_8|) = \frac{5+6+7}{3} = 6$
- $\text{Rang}(|X_7|) = 8$

## 9 Vergleich zweier Stichproben


## 9.1 Gepaarte und ungepaarte Stichproben:

**Ungepaarte Stichproben:** Zufällig gewählte Reihenfolge der Versuche, verschiedene Versuchseinheiten unter zwei verschiedenen Versuchsbedingungen (**Randomisierung**). Einzelne Tests müssen nicht gleiche Stichprobengrosse haben.

Bsp: 2 Medikamente an verschiedenen Stichproben getestet.

**Gepaarte Stichproben:** beide Versuchsbedingungen an derselben Versuchseinheit getestet. Notwendigerweise müssen die beiden Stichprobengrossen gleich sein.

Bsp: 15 Prüfkörper von 2 Labors ausgemessen, Alte und neue Schuhe von den selben Athleten probiert.



## Theorem: George Box Merkregel

Die Merkregel lautet:

**“Block what you can, randomize what you cannot.”**

In dem Sinne sind also gepaarte Stichproben (falls realisierbar) unabhängigen Stichproben vorzuziehen.

**Note:** Sobald Menschen involviert sind  $\Rightarrow$  Experiment wenn möglich doppelblind durchgeführt wird (weder die Person noch die Versuchsperson die Gruppenzugehörigkeit kennen). Dies ist wichtig, um den Effekt von Voreingenommenheit bei der Beurteilung auszuschalten.

## 9.2 Gepaarte Vergleiche:

## Differenz innerhalb der Paare:

$$u_i = x_i - y_i$$

mit Zufallsvariablen i.i.d  $U_1, \dots, U_n$ .

**Note:** P-Wert kleiner als bei zwei Stichprobe t-Test, kein Unterschied zwischen Versuchsreihen:  $\mathbb{E}[U_i] = 0$ . Wir haben also:

- $H_0 : \mathbb{E}(U_i) = 0 \Rightarrow \mu_0 = 0$
- $H_A : \mathbb{E}(U_i) \neq 0 \Rightarrow \mu_0 \neq 0$

Verschiedene mögliche Tests:

- t-Test, wenn Normalverteilt und unabhängig, QQ-Plot
- Vorzeichen-Test, wenn beliebig verteilt
- Wilcoxon-Test, wenn symmetrisch verteilt, Histogramm

## 9.3 Zwei-Stichproben Test (ungepaarte Vergleiche):

Ungepaarte Stichproben, unabhängige i.i.d Zufallsvariablen.

9.3.1 Mit  $\sigma$  bekannt:

**Annahmen:** Normalverteilt mit gleicher Varianz,  $\sigma_X = \sigma_Y = \sigma$

$$\left. \begin{aligned} X_i &\stackrel{iid}{\sim} \mathcal{N}(\mu_X, \sigma^2), & i = 1, \dots, n \\ Y_j &\stackrel{iid}{\sim} \mathcal{N}(\mu_Y, \sigma^2), & j = 1, \dots, m \end{aligned} \right\} \mu_X, \mu_Y, \sigma \text{ bekannt}$$

$$\text{Var}(\bar{X}_n - \bar{Y}_m) = \sigma^2 \left( \frac{1}{n} + \frac{1}{m} \right)$$

Wir testen also zweiseitig:

- $H_0 : \mu_X = \mu_Y$
- $H_A : \mu_X \neq \mu_Y$

Wir definieren die Teststatistik als:

$$Z = \frac{(\bar{X}_n - \bar{Y}_m) - (\mu_X - \mu_Y)}{\sigma \sqrt{\frac{1}{n} + \frac{1}{m}}}$$

und machen einen **Z-Test** um die Nullhypothese zu verwerfen.

**Note:**  $Z \sim \mathcal{N}\left(\frac{\mu_X - \mu_Y}{\sigma \sqrt{\frac{1}{n} + \frac{1}{m}}}, 1\right)$ , falls  $\mu_X = \mu_Y \Rightarrow Z \sim \mathcal{N}(0, 1)$

### 9.3.2 Mit $\sigma$ unbekannt:

In der Praxis kennen wir  $\sigma$  nicht und so wir definieren:

$$S_{pool}^2 = \frac{1}{n+m-2} \left( \sum_{i=1}^n (X_i - \bar{X}_n)^2 + \sum_{i=1}^m (Y_i - \bar{Y}_m)^2 \right)$$

$$= \frac{1}{n+m-2} ((n_X - 1) \cdot S_X^2 + (n_Y - 1) \cdot S_Y^2)$$

**Note:**  $S_{pool}$  ist nichts anderes als ein gewichtetes Mittel der Schätzungen der Variablen.

Die Teststatistik lautet:

$$T = \frac{(\bar{X}_n - \bar{Y}_m) - (\mu_X - \mu_Y)}{S_{pool} \sqrt{\frac{1}{n} + \frac{1}{m}}} \quad \text{mit} \quad T \sim t_{n+m-2}$$

**Note:**

- Erinnerung:  $-t_{n+m-2, 1-\alpha} = t_{n+m-2, \alpha}$
- Wir müssen hier 2 DOF abziehen, weil die Parameter  $\mu_X$  und  $\mu_Y$  geschätzt haben.

Wie bei 9.3.1 wir testen für  $H_0 : \mu_X = \mu_Y$ .

### Vorgehen: Zwei Stichprobe t-Test

Wir definieren die Teststatistik als:

$$\tilde{T} = \frac{\bar{X}_n - \bar{Y}_m}{S_{pool} \sqrt{\frac{1}{n} + \frac{1}{m}}}$$

Wir verwerfen  $H_0$  falls:

1.  $H_A : \mu_X \neq \mu_Y$ :

$$|\tilde{T}| \geq t_{n+m-2, 1-\frac{\alpha}{2}} \Leftrightarrow \tilde{T} \in K = (-\infty, -t_{n+m-2, 1-\frac{\alpha}{2}}] \cup [t_{n+m-2, 1-\frac{\alpha}{2}}, \infty)$$

2.  $H_A : \mu_X > \mu_Y$ :

$$\tilde{T} \geq t_{n+m-2, 1-\alpha} \Leftrightarrow \tilde{T} \in K = [t_{n+m-2, 1-\alpha}, \infty)$$

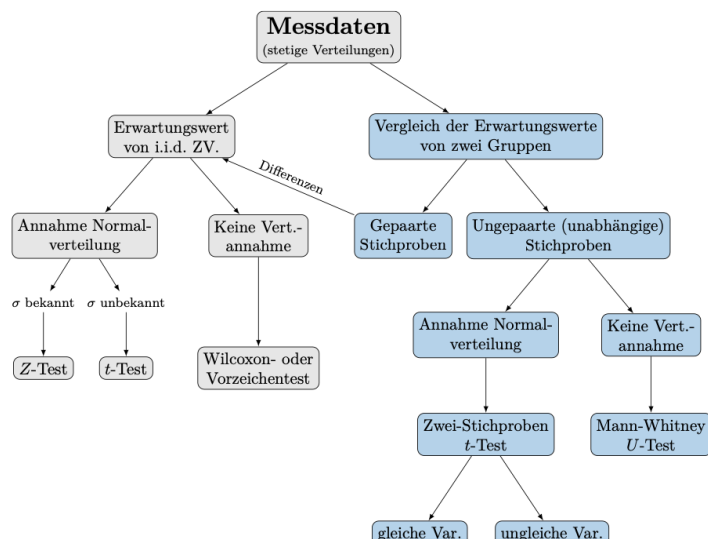
3.  $H_A : \mu_X < \mu_Y$ :

$$\tilde{T} \leq t_{n+m-2, \alpha} = -t_{n+m-2, 1-\alpha} \Leftrightarrow \tilde{T} \in K = (-\infty, \underbrace{t_{n+m-2, \alpha}}_{=-t_{n+m-2, 1-\alpha}}]$$

Das  $(1 - \alpha) \times 100\%$  **Vertrauensintervall** für  $d = \mu_X - \mu_Y$  ist:

$$I = \bar{X}_n - \bar{Y}_m \pm S_{pool} \sqrt{\frac{1}{n} + \frac{1}{m}} \cdot t_{n+m-2, 1-\frac{\alpha}{2}}$$

**Note:** Enthält das Intervall das Nullpunkt nicht, so verwerfen wir  $H_0$  (für das zweiseitige Test),



## 10 Lineare Regression

### 10.1 Einfache lineare Regression:

Wir betrachten die vorliegenden Daten  $(x_i, y_i)$ ,  $i = \dots, n$


#### 10.1.1 Modell:

Das einfache lineare Regressionsmodell lautet ( $i = 1, \dots, n$ )

$$Y_i = \beta_0 + \beta_1 x_i + E_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2)$$

Mit:

- $Y_i$  ist die Zielvariable (unabhängig)
- $x_i$  ist die erklärende Variable, typischerweise nicht-zufällig
- $E_i$  i.i.d.  $\sim \mathcal{N}(0, \sigma^2)$ ,  $\sigma^2$  = Störparameter



**Note:** Das Modell heisst "einfach", weil nur eine erklärende Variable vorhanden ist. Zudem heisst das Modell "linear", da die Parameter  $\beta_i$  linear in der Modellgleichung vorkommen.

#### 10.1.2 Parameterschätzungen:

**Maximum-Likelihood Schätzer**

$$L(\beta_0, \beta_1) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2} \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2\right\}$$

**Kleinste Quadrat Schätzer**

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Wir definieren also:


$$\hat{\beta}_0, \hat{\beta}_1 = \operatorname{argmin}_{\beta_0, \beta_1} L(\beta_0, \beta_1) = \operatorname{argmin}_{\beta_0, \beta_1} S(\beta_0, \beta_1)$$

Es gilt so:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

**Note:** Wir koennen auch  $\hat{\beta}_1$  schreiben als  $\hat{\beta}_1 = r \frac{s_y}{s_x}$  mit  $r, s_x, s_y$  aus 4.1.



Wir definieren also die **Residuen** als  $r_i = y_i - \hat{y}_i$ .

Daher schätzen wir die Varianz des Fehlerterms mit  $\sigma^2 = \frac{1}{n-2} \sum_{i=1}^n r_i^2$

## 10.1.3 Tests und Vertrauensintervalle:

Es gilt:

$$\hat{\beta}_1 = \mathcal{N}\left(\beta_1, \frac{\sigma^2}{SS_X}\right)$$

$$\hat{\beta}_0 = \mathcal{N}\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{SS_X}\right)\right)$$

wobei  $SS_X = \sum_{i=1}^n (x_i - \bar{x})^2$

**Note:** Die Parameterschätzer sind also Zufallsvariablen und erwartungstreu. Die Standardabweichung eines Parameterschätzers entspricht den **Standardfehler**.

Setzt man die Schätzung  $\hat{\sigma}$  ein, so erhält man den geschätzten Standardfehler.

## Vorgehen: t-Test bei Lineare Regression

Wir definieren unsere Teststatistik als:

$$\frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}/\sqrt{SS_X}} \sim t_{n-2}$$

Wir haben also erneut eine Funktion der Form:

$$\frac{\text{beobachtet} - \text{erwartet}}{\text{geschätzter Standardfehler}}$$

Beim Test verwenden wir:

- $H_0 : \beta_1 = 0$ : "Es gibt **keinen** linearen Zusammenhang zwischen  $x$  und  $y$ ."
- $H_A : \beta_1 \neq 0$ : "Es gibt **einen** linearen Zusammenhang zwischen  $x$  und  $y$ ."

Wir berechnen:

$$1 - \alpha = \mathbb{P}\left(\frac{|\hat{\beta}_1 - \beta_1|}{\hat{\sigma}/\sqrt{SS_X}} \leq t_{n-2, 1-\frac{\alpha}{2}}\right) =$$

$$= \mathbb{P}\left(|\hat{\beta}_1| \leq t_{n-2, 1-\frac{\alpha}{2}} \cdot \frac{\hat{\sigma}}{\sqrt{SS_X}}\right)$$

So, wir verwerfen  $H_0$  falls:

$$\left|\frac{\hat{\beta}_1}{\hat{\sigma}/\sqrt{SS_X}}\right| \geq t_{n-2, 1-\frac{\alpha}{2}}$$

$(1 - \alpha) \times 100\%$  **Vertrauensintervall** für  $\beta_1$  ist gegeben durch:

$$I = \hat{\beta}_1 \pm t_{n-2, 1-\frac{\alpha}{2}} \cdot \frac{\hat{\sigma}}{\sqrt{SS_X}}$$

Diese hat also auch die Form:

$$\text{Schätzung} \pm \text{Quantil} \cdot (\text{geschätzter Standardfehler})$$

## 10.1.4 Computer Output Regression:

Einen computer liefert das folgendes Resultat:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	6.3681	0.7191	8.856	0.000305
tiefe	-13.6373	1.0111	-13.487	4.01e-05

Wir lesen ab:


$$\begin{bmatrix} \hat{\beta}_0 & \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{SS_X}\right) & t_{wert, \hat{\beta}_0} & \text{P-Wert}_{\hat{\beta}_0} \\ \hat{\beta}_1 & \frac{\sigma^2}{SS_X} & t_{wert, \hat{\beta}_1} & \text{P-Wert}_{\hat{\beta}_1} \end{bmatrix}$$

**Note:** Das "Error" column entspricht den Standardfehlern von  $\hat{\beta}_0$  und  $\hat{\beta}_1$ . Das " $Pr(> |t|)$ " column entspricht den P-Wert für den zweiseitigen  $t$  Test.

## 10.1.5 Vertrauensintervalle für den Erwartungswert und Prognoseintervalle:

**Vertrauensintervall für den wahren Wert der Geraden** an der Stelle  $x$ : der Wert der Modellgerade adS  $x$  ist nichts anderes als der Erwartungswert der Zielgrösse, wenn wir ein  $x$  fixieren und ist gleich  $\beta_0 + \beta_1 x$ .

**Prognoseintervall:** Intervall, das mit hoher Wahrscheinlichkeit eine neue (zufällige) Beobachtung  $Y$  adS  $x$  einfängt. Im Verhältnis zu Vertrauensintervall ist das Prognoseintervall immer breiter. Dies ist auch einleuchtend, denn es muss noch die Variabilität einer Beobachtung "abdecken" (wegen Fehlerterm  $E$ ). Beide Bänder sind übrigens gekrümmt, beim Prognoseband ist dies nur viel schlechter sichtbar.



**Note:** Daten, geschätzte Gerade (gestrichelt), Vertrauensintervalle (durchgezogen) und Prognoseintervall (gepunktet) im Beispiel mit der Bohrung in Permafrostboden.

## Annahmen:

1.  $\mathbb{E}[E_i] = 0 \Rightarrow$  keinen systematischen Fehler im Modell (die Modellgleichung ist korrekt)
2. Die  $E_1, \dots, E_n$  sind i.i.d. Die Fehler sind also unabhängig voneinander und folgen der gleichen Verteilung (Varianz gleich gross).
3. Die  $E_1, \dots, E_n$  sind normalverteilt.

**Note:** Je deutlicher die Modellannahmen verletzt sind, desto weniger vertrauenswürdig sind die Resultate (p- Werte der Tests, Vertrauensintervalle, ...). Bei einer nur "leichten" Verletzung der Modellannahmen sind die Resultate sicher noch brauchbar.

## 10.1.6 Typ von Plots:

## Tukey-Anscombe Plot (TA-Plot)

Man plottet die Residuen  $r_i$  gegen  $\hat{y}_i$  auf (bei linearen Regression  $r_i$  auch gegen  $x_i$  aufzeichnen). Idealfall  $\Rightarrow$  Streuung der Punkte um die x-Achse sehen. Mögliche Szenarien sind:

- Falls systematische Abweichungen von der x-Achse erkennbar sind, so spricht dies gegen die Annahme 1 von 10.1.5. Denn in diesem Fall gibt es Bereiche, wo der Fehler im Schnitt nicht 0 ist (z.B. falls man einen quadratischen Effekt im Modell vergessen hat).
- Ist die Streuung stark unterschiedlich (z.B. trichterförmiges Bild), so spricht dies gegen Annahme 2 von 10.1.5.
- Ev. sieht man auch "Ausreisserpunkte".

**Normalplot**

Man erstellt einen Normalplot der Residuen. Es sollten keine groben Abweichungen von einer Geraden vorliegen, sonst wäre dies eine Verletzung der Modellannahme 3 von 10.1.5.

**Serial Correlation Plot**

Um die Unabhängigkeit der  $E_1, \dots, E_n$  zu überprüfen, kann man die Residuen  $r_i$  gegen die entsprechende Beobachtungsnummer  $i$  aufzeichnen. Sinnvoll, wenn die Beobachtungen in dieser zeitlichen Reihenfolge aufgenommen wurden.

Im Idealfall sollte es keine Regionen geben, wo sich die Residuen ähnlich verhalten (d.h. wo z.B. alle positiv sind).

**10.2 Multiple lineare Regression:**

In der Praxis hat man oft nicht nur eine, sondern mehrere erklärende Variablen  $x^{(1)}, \dots, x^{(m)}$ ,  $m > 1$ .

**10.2.1 Modell:**

Das multiple lineare Regressionsmodell ist gegeben durch:

$$Y_i = \beta_0 + \beta_1 x_i^{(1)} + \dots + \beta_p x_i^{(m)} + E_i, \quad i = 1, \dots, n$$

wobei wieder wie früher  $E_i$  i.i.d.  $\sim \mathcal{N}(0, \sigma^2)$  angenommen wird.

**Note:**

- Bei  $x^{(j)} \Rightarrow j$ -te erklärende Variable der  $i$ -ten Beobachtung.
- Total haben wir also  $p = m + 1$  verschiedene  $\beta$ -Parameter.
- Der Parameter  $\beta_j$  ist der Effekt der erklärenden Variable  $x^{(j)}$  auf die Zielgrösse  $Y$ , wenn alle anderen erklärenden Variablen fest gehalten werden und nur  $x^{(j)}$  variiert wird.
- Modell linear, weil die Parameter linear in der Modellgleichung vorkommen (Bsp:  $Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + E_i$ )

**Matrix-Schreibweise:** ( $n$  Variablen):

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, X = \begin{bmatrix} 1 & x_1^{(1)} & x_1^{(2)} & \dots & x_1^{(m)} \\ 1 & x_2^{(1)} & x_2^{(2)} & \dots & x_2^{(m)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n^{(1)} & x_n^{(2)} & \dots & x_n^{(m)} \end{bmatrix}, \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_n \end{bmatrix}, E = \begin{bmatrix} E_1 \\ E_2 \\ \vdots \\ E_n \end{bmatrix}$$

Das Modell ist also gleich:  $Y = X\beta + E$ .

**Note:**

- Die Matrix  $X$  heisst Designmatrix.
- $i$ -ten Zeile = erklärenden Variablen der  $i$ -ten Beobachtung.
- Erste Spalte = Achsenabschnitt.

Multiple lineare Regressionsmodelle mit:

- **Lineare Variablen:**  $Y_i = \beta_0 + \beta_1 x_i + E_i$

$$p = 2, \quad X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}$$

- **Quadratischen Variablen:**  $Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + E_i$

$$p = 3, \quad X = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}$$

- **Transform Variablen:**  $Y_i = \beta_0 + \beta_1 \log(x_i^{(1)}) + \beta_2 \sin(\pi x_i^{(2)}) + E_i$

$$p = 3, \quad X = \begin{bmatrix} 1 & \log(x_1^{(1)}) & \sin(\pi x_1^{(2)}) \\ 1 & \log(x_2^{(1)}) & \sin(\pi x_2^{(2)}) \\ \vdots & \vdots & \vdots \\ 1 & \log(x_n^{(1)}) & \sin(\pi x_n^{(2)}) \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}$$

**Note:** Alle diese 3 Modelle sind lineares, obwohl nicht immer die  $x_i^{(i)}$  linear sind.

**10.2.2 Parameterschätzung:**

**Methode der kleinste Quadrate:** falls die Matrix  $X$  vollen Rang hat, so ist die Lösung geschlossen darstellbar:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

wobei wir hier mit  $y$  den Vektor der beobachteten Werte der Zielgrösse bezeichnen. Für  $\hat{\sigma}^2$  verwendet man:

$$\hat{\sigma}^2 = \frac{1}{n-p} \sum_{i=1}^n \left( y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i^{(1)} - \dots - \hat{\beta}_m x_i^{(m)} \right)^2$$

Der Nenner bei der Schätzung von  $\hat{\sigma}^2$  hat die Form  $\# \text{Beobachtungen} - \# \text{Parameter}$  und ist erwartungstreu.

**10.2.3 Test und Vertrauensintervalle:****Individuelle Tests**

Wir können für jede Parameter  $\beta_j$  ein Test durchführen:

- $H_{0,j} : \beta_j = 0$
- $H_{A,j} : \beta_j \neq 0$

für  $j = 0, \dots, m$ . Wir erhalten eine t-Verteilung, mit  $n - m$  DOF. Die  $\#$  DOF hat also auch hier die Form "Anzahl Beobachtungen - Anzahl Parameter".

**Note:** Ein individueller Test beantwortet die Frage, ob man eine einzelne Variable weglassen kann. Wenn sich zwei erklärende Variablen sehr ähnlich sind (d.h. wenn sie stark korreliert sind), so man kann beide (einzeln) weglassen (sie ergeben gleich Informationen).

**F-Test**

Testet ob es plausibel ist, dass alle Variablen weggelassen werden können (typischerweise ausser dem Achsenabschnitt).

- $H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0$  ("keine Variable hat einen Einfluss")
- $H_A : \text{Mindestens ein } \beta_j \neq 0, \quad j \in \{1, \dots, m\}$

**Note:** Dieser Test basiert sich auf die F-Verteilung. Computer ergibt p-Wert des entsprechenden Tests, den wir auch als Globaltest bezeichnen.